ANDREI PEREIRA LIMA-
CARLOS OLIVEIRA LOPES
KAIO MOREIRA MORAIS
PRISCILA FERREIRA DIAS SANTOS
YWD RHAVELL FERREIRA CARVALHO

TED 02
LIMPEZA, SANEAMENTO E ANÁLISE EXPLORATÓRIA

BALSAS - MA
2026

RESUMO

Este documento preserva o problema, a solução, o MVP, a seleção do conjunto de dados e as limitações identificadas na TED 01 e acrescenta os resultados da etapa de limpeza, saneamento, preparação e análise exploratória da RAIS 2023. A versão registra as decisões tomadas sobre valores ausentes, duplicidades, inconsistências, valores atípicos e atributos irrelevantes, descreve a base pós-tratamento e interpreta os principais padrões encontrados em relação ao problema da Conserpav.

1. PROBLEMA DO PROJETO

O projeto tem como cliente a Conserpav, empresa voltada ao setor de obras e pavimentação. O problema central é o controle de presença e o fechamento de pagamento dos trabalhadores, atividades ainda realizadas de forma predominantemente manual, com cadernos, anotações e planilhas.

No canteiro, o responsável registra a frequência diária, verifica quem trabalhou o período completo, meio período ou faltou e, posteriormente, cruza essas informações para calcular os pagamentos. Esse processo favorece erros de soma, perda de informações, retrabalho e dificuldade para recuperar o histórico. Como os ciclos de pagamento podem ser semanais ou quinzenais, o acompanhamento histórico dos custos de mão de obra também se torna difícil.

A solução proposta busca centralizar esses registros, simplificar o cálculo dos pagamentos e aproveitar o histórico gerado nas obras para aumentar a previsibilidade financeira dos períodos seguintes.

2. DESCRIÇÃO DA SOLUÇÃO E MVP

A proposta consiste em um sistema web inteligente para gestão de frequência, cálculo de pagamentos e projeção de custos com mão de obra. A plataforma deverá registrar a presença diária, calcular automaticamente os valores devidos e consolidar o histórico financeiro dos canteiros.

Como diferencial, o sistema prevê um componente de Inteligência Artificial para analisar o histórico e estimar os custos de pessoal do próximo ciclo de fechamento. A projeção deverá considerar, entre outras, as seguintes variáveis:

- Quantidade de trabalhadores alocados;
- Valores estipulados para as diárias;
- Média de dias efetivamente trabalhados;
- Ocorrência de jornadas parciais (meias diárias);
- Despesas consolidadas em períodos anteriores;
- Comportamento macro dos gastos na obra.

A previsão terá caráter estimativo e funcionará como apoio analítico à tomada de decisão, preservando a autonomia do gestor.

2.1 FUNCIONALIDADES DO MVP

Cadastro de obras, com definição do ciclo de fechamento semanal ou quinzenal.
Cadastro de funcionários, incluindo nome, função, valor da diária, obra vinculada e chave Pix.

Registro de frequência, distinguindo diária completa, meia diária e ausência.
Cálculo automático de pagamentos a partir dos apontamentos de frequência.
Histórico de presença e pagamentos de ciclos anteriores.
Relatório de pagamento com dias completos, meios dias, faltas, valor total e chave Pix.
Previsão de custos com IA, exibindo custo estimado, custo anterior, média histórica e variação estimada.

3. NECESSIDADES DE DADOS DA SOLUÇÃO

Com base no problema identificado e nas funcionalidades do MVP, as principais necessidades de dados são:

Necessidade de dados	**Utilização no projeto**
Identificação da obra	Associar os registros ao projeto correspondente
Identificação do trabalhador	Associar frequência e pagamentos ao funcionário
Função do trabalhador	Analisar a composição da mão de obra
Valor da diária / remuneração	Calcular e analisar o pagamento
Data / admissão / desligamento	Organizar frequência e vínculo ao longo do tempo

Situação da frequência	Identificar diária completa, meia diária ou ausência
Quantidade de trabalhadores	Avaliar a demanda de mão de obra
Duração da obra / vínculo	Relacionar duração e necessidade de recursos
Custo da obra / folha	Analisar o comportamento dos custos
Histórico de custos	Apoiar a previsão de custos futuros

4. PESQUISA E COMPARAÇÃO DE CONJUNTOS DE DADOS

As alternativas pesquisadas em repositórios públicos, como o Kaggle, apresentaram baixa aderência ao problema: algumas tratavam de qualidade ou segurança de obras, outras eram simuladas e outras pertenciam a setores ou contextos geográficos diferentes. Nenhuma reunia, de forma satisfatória, variáveis reais de frequência, remuneração ou custo de mão de obra da construção civil.

A equipe optou, portanto, pelos microdados de vínculos da RAIS (Relação Anual de Informações Sociais), disponibilizados pelo Ministério do Trabalho e Emprego. O CAGED foi considerado durante a pesquisa, mas não é utilizado nesta etapa.

5. CONJUNTO DE DADOS SELECIONADO

A base escolhida corresponde aos microdados de vínculos da RAIS, ano-base 2023, registro administrativo do mercado de trabalho formal brasileiro mantido pelo Ministério do Trabalho e Emprego (MTE/PDET). Os registros são públicos e não identificados.

Para evitar o processamento dos arquivos nacionais completos, a equipe utilizou a RAIS estruturada pela Base dos Dados no BigQuery. O recorte selecionou o Maranhão, o ano de 2023 e as divisões 41, 42 e 43 da CNAE 2.0, correspondentes às atividades de construção. O resultado foi exportado em CSV.

Consulta utilizada:

```
SELECT *
FROM `basedosdados.br_me_rais.microdados_vinculos`
WHERE ano = 2023
  AND sigla_uf = 'MA'
  AND SUBSTR(cnae_2, 1, 2) IN ('41', '42', '43')
```

6. PRINCIPAIS ATRIBUTOS / VARIÁVEIS

1. Setor e função: cnae_2 e cbo_2002.
2. Remuneração: valor_remuneracao_media, valor_remuneracao_media_sm e remunerações mensais de janeiro a dezembro.
3. Vínculo e tempo: mes_admissao, mes_desligamento, tempo_emprego, vinculo_ativo_3112 e tipo_vinculo.
4. Jornada: quantidade_horas_contratadas e indicador_trabalho_parcial.
5. Localização e porte: id_municipio, sigla_uf e tamanho_estabelecimento.
6. Perfil do trabalhador: sexo, idade, grau_instrucao_apos_2005 e raca_cor.
7. Referência temporal: ano.

7. QUANTIDADE DE REGISTROS

A RAIS 2023 possui 82.966.522 registros em âmbito nacional. O recorte do Maranhão possui 1.265.961 registros. Após o filtro das divisões 41, 42 e 43 da CNAE 2.0, a base utilizada no projeto ficou com 97.971 registros e 67 atributos.

Divisão CNAE	Descrição	Vínculos	Participação
41	Construção de edifícios	50.096	51,13%
42	Obras de infraestrutura	34.148	34,86%
43	Serviços especializados para construção	13.727	14,01%

8. FORMATO DOS DADOS

Os dados são disponibilizados originalmente pelo MTE em arquivos de texto delimitados por ponto e vírgula. Para o projeto, o recorte foi consultado via SQL na Base dos Dados (BigQuery) e exportado em CSV, facilitando a leitura em Python/Pandas e a posterior preparação dos dados.

9. AVALIAÇÃO PRELIMINAR DA QUALIDADE DOS DADOS (TED 01)

A avaliação preliminar identificou 58 das 67 colunas sem valores ausentes e nove colunas com nulos. Cinco estavam 100% vazias: tipo_salario, valor_salario_contratual, subatividade_ibge, cbo_1994 e grau_instrucao_1985_2005. id_municipio_trabalho possuía 99,97% de nulos; motivo_desligamento, 51,33%; valor_remuneracao_dezembro, 53,73%; e natureza_juridica, 29,78%.

Também foram identificados 542 registros duplicados (0,55%), 11.840 vínculos com valor_remuneracao_media igual a zero e uma distribuição de remuneração fortemente assimétrica à direita. A TED 01 registrou essas ocorrências como pontos a investigar antes de qualquer remoção ou substituição.

10. JUSTIFICATIVA DA ESCOLHA DA BASE DE DADOS

A RAIS foi escolhida por ser uma fonte real, oficial e verificável, com remuneração declarada, ocupação, setor, localização e informações temporais dos vínculos formais. O volume de 97.971 vínculos no recorte é suficiente para análises estatísticas e exploratórias.

A base não reproduz o registro diário de frequência da Conserpav, mas fornece uma referência setorial útil para estudar remuneração, ocupação e características dos vínculos na construção do Maranhão.

11. RELAÇÃO ENTRE OS DADOS, O PROBLEMA E AS LIMITAÇÕES

As necessidades do projeto são parcialmente atendidas pela RAIS. A função é aproximada por cbo_2002; a composição da mão de obra pode ser analisada por CNAE e ocupação; a remuneração média mensal funciona como referência de custo; e a duração do vínculo é aproximada por tempo_emprego e pelos meses de admissão e desligamento.

A aderência não é completa. A RAIS trabalha com estabelecimentos, não com obras; não identifica nominalmente trabalhadores; não possui frequência diária, diárias completas/meias diárias ou histórico de pagamentos individuais; cobre apenas vínculos formais; e a remuneração declarada é mensal, não uma diária. Por isso, seus padrões devem ser interpretados como referência do setor, e não como retrato das obras da Conserpav.

O histórico gerado pelo próprio sistema será necessário para uma previsão futura com granularidade operacional, incluindo obra, trabalhador, função, diária, frequência e valor pago.

TED 02 — LIMPEZA, SANEAMENTO E ANÁLISE EXPLORATÓRIA

A TED 02 dá continuidade à etapa anterior e utiliza o mesmo recorte da RAIS 2023: 97.971 vínculos do setor da construção no Maranhão, com 67 atributos na base original. A análise foi realizada em Python/Pandas e documentada no notebook do projeto.

12. INSPEÇÃO DA ESTRUTURA E DOS TIPOS DE DADOS

A base original possui 97.971 linhas e 67 colunas. Na leitura pelo Pandas, foram observados 42 atributos inteiros, 24 atributos de ponto flutuante e uma variável textual. Diversas colunas numéricas representam códigos categóricos, como tipo_vinculo, cbo_2002, cnae_2 e tipo_estabelecimento; portanto, não devem ser interpretadas como medidas contínuas apenas por estarem armazenadas como números.

motivo_desligamento e natureza_juridica aparecem como float64 em razão da presença de valores ausentes, embora conceitualmente sejam códigos categóricos. Não foi realizada conversão em massa dos tipos, pois os formatos existentes são adequados ao processamento e as variáveis foram tratadas conforme seu significado na análise.

13. ANÁLISE DA QUALIDADE DOS DADOS

13.1 Valores ausentes

Variável	Nulos	Percentual
tipo_salario	97.971	100,00%
valor_salario_contratual	97.971	100,00%
subatividade_ibge	97.971	100,00%
cbo_1994	97.971	100,00%
grau_instrucao_1985_2005	97.971	100,00%
id_municipio_trabalho	97.944	99,97%
valor_remuneracao_dezembro	52.637	53,73%
motivo_desligamento	50.289	51,33%
natureza_juridica	29.172	29,78%

A investigação mostrou que os 50.289 nulos em motivo_desligamento coincidem com mes_desligamento igual a zero, caracterizando vínculos sem desligamento registrado. Esses nulos foram mantidos, pois possuem significado estrutural e não representam necessariamente falha de preenchimento.

Em valor_remuneracao_dezembro, 52.637 registros estão ausentes. A ausência é fortemente associada a vínculos inativos, mas também existem 6.596 vínculos ativos sem valor de dezembro. Como não há evidência para substituir esses casos por zero ou por outro valor, os nulos foram preservados. A Natureza_juridica possui 29.172 nulos (29,78%), concentrados principalmente no tipo_estabelecimento 6. Como a variável possui 15 códigos observados e 70,22% de preenchimento, ela foi mantida sem imputação.

13.2 Duplicidades

Na base original foram encontradas 542 ocorrências duplicadas (0,55%). Como os microdados são anonimizados e não possuem identificador único de trabalhador ou vínculo, linhas com os mesmos 67 atributos podem corresponder a vínculos distintos. Assim, nenhuma linha foi removida por duplicidade.

Após a retirada de atributos, a base tratada passou a apresentar 543 ocorrências duplicadas. O aumento de uma ocorrência é esperado porque a remoção de colunas pode tornar idênticas linhas que antes diferiam em algum atributo descartado. A decisão de preservação foi mantida.

13.3 Inconsistências identificadas

Foram encontrados dois registros com vinculo_ativo_3112 igual a 0, mes_desligamento igual a 0 e motivo_desligamento igual a 11, além de causas de desligamento codificadas como 999. Esses dois casos representam aproximadamente 0,002% da base. Como não existe informação suficiente para inferir o mês correto ou corrigir os códigos, os registros foram preservados e a inconsistência foi documentada.

A variável quantidade_horas_contratadas também contém códigos extremos, incluindo 0 e 99. Como o valor 99 aparece em 3.920 registros e pode refletir codificação específica da fonte, ele não foi alterado nem interpretado literalmente na EDA sem confirmação de domínio.

13.4 Remunerações iguais a zero

Foram identificados 11.840 vínculos (12,09%) com valor_remuneracao_media igual a zero. Desses, 6.827 estavam inativos e 5.013 ativos em 31/12. A inspeção das remunerações mensais mostrou que parte desses vínculos possui valores positivos em meses específicos. Portanto, zero não foi convertido em nulo nem utilizado como critério de exclusão.

Para análises especificamente voltadas à distribuição de remuneração, foram calculadas estatísticas adicionais considerando apenas valores positivos, sem alterar a base tratada.

13.5 Valores atípicos

Pelo método do intervalo interquartil (IQR), Q1 = R$1.302,00, Q3 = R$2.621,245 e IQR = R$1.319,245. O limite superior calculado foi R$4.600,1125 e 5.159 registros (5,27%) ficaram acima ou fora dos limites estatísticos.

Os outliers não foram removidos nem winsorizados. A maior remuneração média observada foi R$72.837,96. Como remunerações elevadas podem corresponder a cargos e vínculos reais, um valor estatisticamente atípico não foi tratado automaticamente como erro. Nos gráficos, foram utilizados limites de visualização quando necessário, preservando todas as observações na base.

14. TRATAMENTOS E JUSTIFICATIVAS

A limpeza foi conservadora: foram removidos atributos sem informação útil ou sem aplicabilidade ao recorte, enquanto linhas e valores potencialmente legítimos foram preservados.

Tratamento	Decisão e justificativa
5 colunas 100% vazias	Removidas por não conterem informação no recorte.
5 colunas de localidades fora do Maranhão	Removidas por não serem aplicáveis ao recorte geográfico.
ano_chegada_brasil	Removida por apresentar valor constante no recorte.
id_municipio_trabalho	Removida por possuir 99,97% de valores ausentes; id_municipio permanece disponível.
ano e sigla_uf	Mantidas para contexto e rastreabilidade, embora constantes no recorte.
motivo_desligamento	Nulos mantidos por representarem predominantemente ausência de desligamento.

valor_remuneracao_dezembro	Nulos mantidos; não há base segura para imputação.
natureza_juridica	Mantida sem imputação; variável possui informação em 70,22% dos registros.
Duplicidades	Mantidas devido à anonimização e ausência de chave única.
Remuneração média zero	Mantida após verificação de valores mensais positivos em parte dos casos.
Outliers de remuneração	Mantidos por não haver evidência de erro.

Ao final, foram removidas 12 colunas e nenhuma linha.

15. DESCRIÇÃO DA BASE APÓS O TRATAMENTO

Indicador	**Resultado**
Registros	97.971
Colunas	55
Linhas removidas	0
Colunas removidas	12
Colunas com valores ausentes	3
Valores ausentes remanescentes	132.098
Duplicados na base tratada	543
Remuneração média igual a zero	11.840

Os valores ausentes remanescentes concentram-se em valor_remuneracao_dezembro, motivo_desligamento e natureza_juridica e foram mantidos de forma consciente e documentada. A base tratada foi exportada como data/processed/rais_ma_construcao_2023_tratada.csv.

16. ANÁLISE EXPLORATÓRIA DOS DADOS

16.1 Estatísticas descritivas

Variável	**Média**	**Mediana**	**Mínimo**	**Máximo**
Idade	37,74	37	15	85
Horas contratadas	45,74	44	0	99

Tempo de emprego	18,59	8,3	0	476,9
Remuneração média (R$)	2.074,61	1.833,48	0	72.837,96

Entre os 86.131 vínculos com remuneração média positiva, a média foi R$2.359,80, a mediana R$1.971,00 e o desvio-padrão R$1.685,26. Considerando todos os registros, a média foi R$2.074,61, a mediana R$1.833,48 e o desvio-padrão R$1.757,42.

16.2 Distribuição da remuneração

A distribuição é assimétrica à direita: a média supera a mediana e existe uma cauda formada por remunerações mais altas. Para tornar o histograma legível, a visualização foi limitada ao percentil 99 das remunerações positivas, equivalente a R$8.830,38. Esse limite foi aplicado apenas ao gráfico; os valores superiores continuam na base.

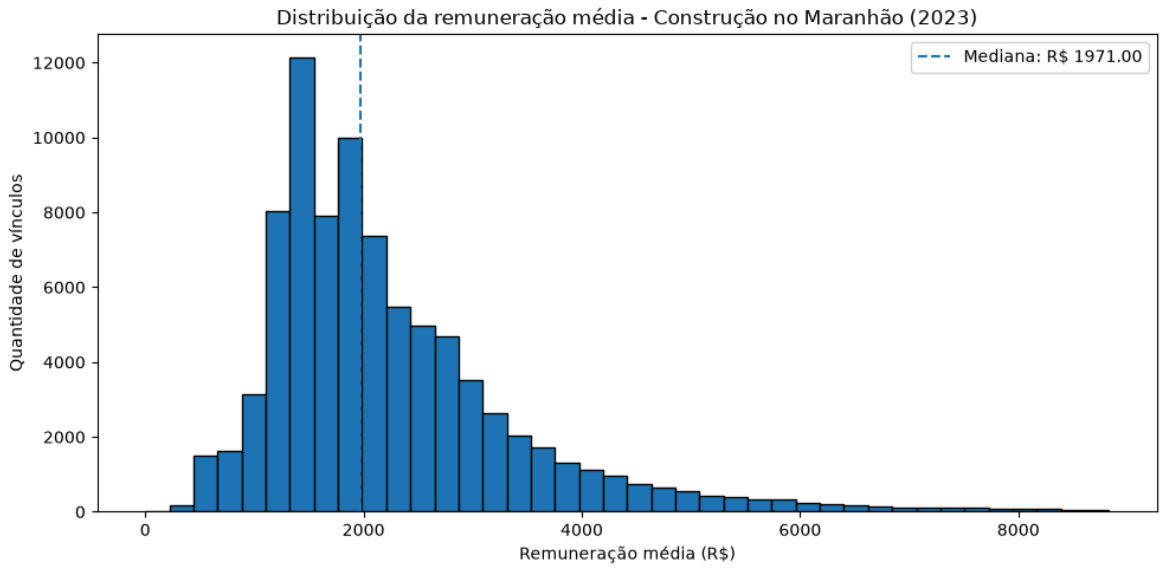


Figura 1 — Distribuição da remuneração média positiva até o percentil 99.

16.3 Remuneração por divisão CNAE

Divisão	**Vínculos com remuneração positiva**	**Média (R$)**	**Mediana (R$)**
41 — Construção de edifícios	42.712	1.965,71	1.750,58

42 — Obras de infraestrutura	31.373	2.863,59	2.520,02
43 — Serviços especializados	12.046	2.445,06	1.961,00

A divisão 42 apresenta a maior remuneração mediana entre as três divisões. A diferença sugere que o segmento de atividade deve ser considerado na interpretação dos custos de mão de obra, especialmente porque obras de infraestrutura possuem proximidade com o contexto de pavimentação da Conserpav.

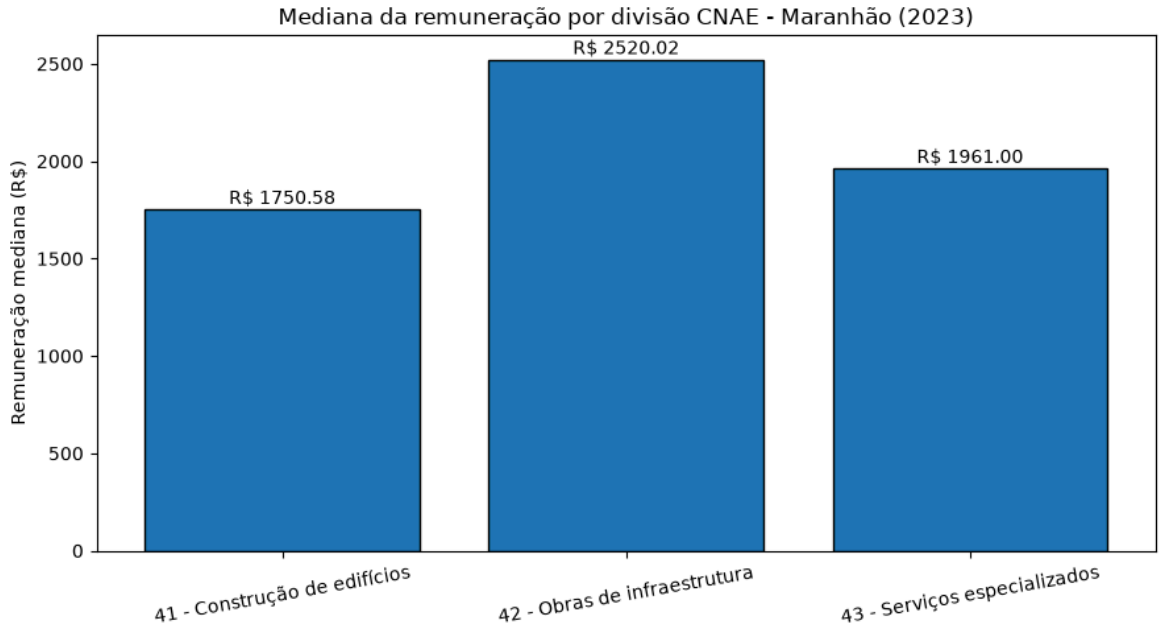


Figura 2 — Remuneração mediana por divisão CNAE.

16.4 Ocupações mais frequentes

CBO	Ocupação	Vínculos
717020	Servente de obras	21.685
715210	Pedreiro	10.697
715615	Eletricista de instalações	3.436
782510	Motorista de caminhão	3.183
710205	Mestre de construção civil	2.247
517420	Vigia	2.107
411005	Auxiliar de escritório	1.938
411010	Assistente administrativo	1.787
715505	Carpinteiro	1.659

724205	Montador de estruturas metálicas	1.606

Serventes de obras e pedreiros concentram as maiores frequências entre as ocupações destacadas, evidenciando o peso das funções operacionais no recorte.

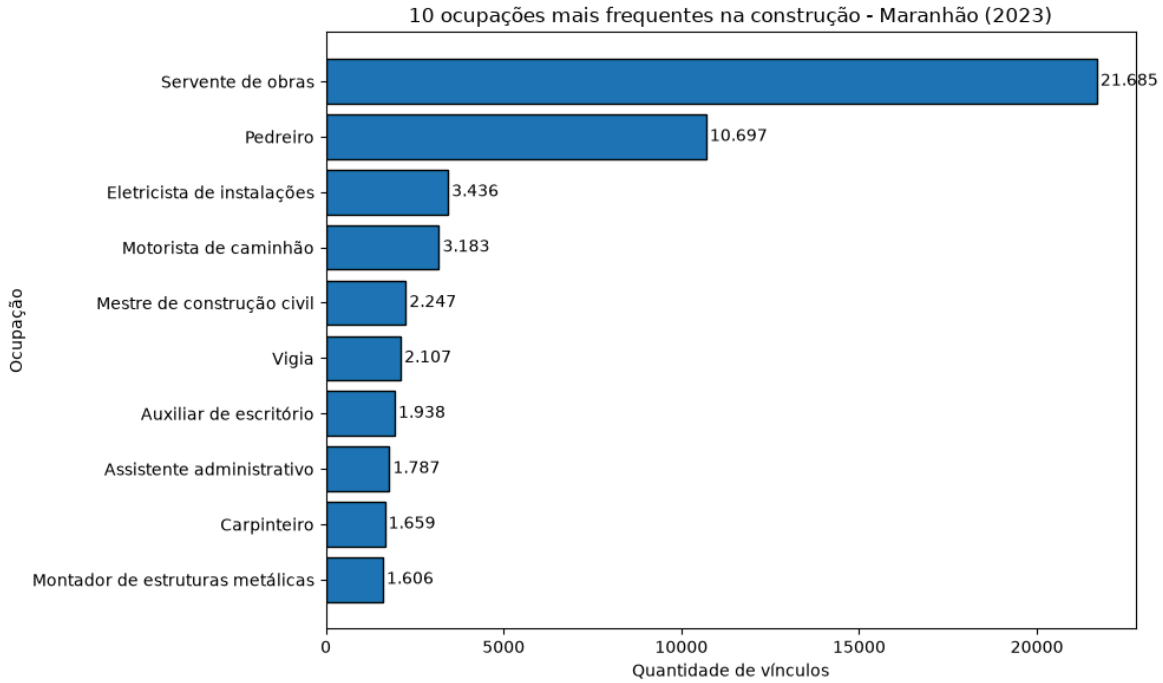


Figura 3 — Dez ocupações mais frequentes no recorte analisado.

16.5 Remuneração por ocupação

Ocupação	Vínculos positivos	Média (R$)	Mediana (R$)
Mestre de construção civil	2.041	3.805,61	3.418,13
Eletricista de instalações	3.131	2.507,15	2.630,29
Motorista de caminhão	2.843	2.697,29	2.609,73
Carpinteiro	1.454	2.043,38	1.973,40
Montador de estruturas metálicas	1.472	1.980,13	1.953,48
Pedreiro	9.081	1.973,80	1.945,23
Assistente administrativo	1.620	2.007,63	1.700,00

Vigia	1.807	1.727,40	1.665,35
Auxiliar de escritório	1.730	1.623,24	1.470,95
Servente de obras	18.633	1.447,01	1.394,80

Entre as dez ocupações mais frequentes, a remuneração mediana varia de R$1.394,80 para Servente de obras a R$3.418,13 para Mestre de construção civil. A amplitude observada reforça a relevância da função/ocupação como variável explicativa para análises de custo.

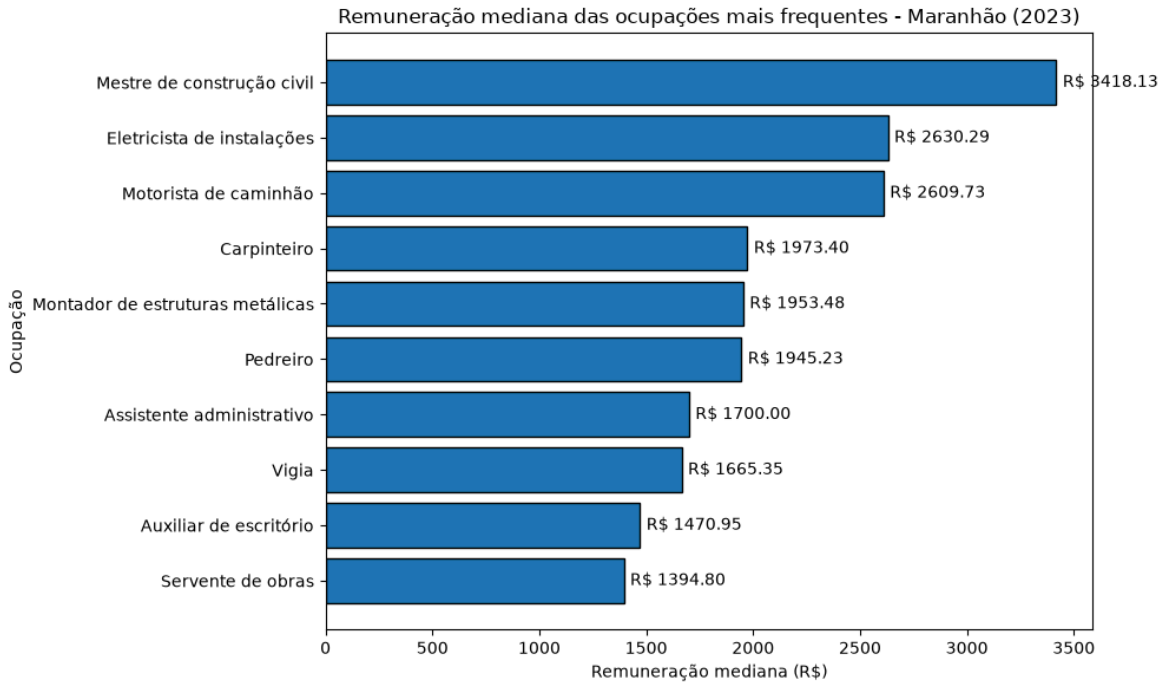


Figura 4 — Remuneração mediana das ocupações mais frequentes.

16.6 Situação dos vínculos em 31/12

Em 31/12, 50.378 vínculos estavam ativos (51,42%) e 47.593 inativos (48,58%). O equilíbrio entre os grupos ajuda a contextualizar a presença de valores ausentes em variáveis de desligamento e em remuneração de dezembro.

17. PRINCIPAIS PADRÕES E RELAÇÕES IDENTIFICADOS

- A remuneração apresenta assimetria à direita; por isso, média e mediana devem ser analisadas em conjunto.
- Os 11.840 valores médios iguais a zero exigem interpretação cuidadosa e não devem ser tratados automaticamente como erros.
- A divisão CNAE 42 apresentou maior remuneração mediana entre as divisões 41, 42 e 43.

- As ocupações apresentam diferenças relevantes de remuneração, com destaque para a distância entre serventes e mestres de construção civil.
- A situação ativo/inativo está praticamente equilibrada no final do ano, aspecto importante para interpretar desligamentos e remuneração de dezembro.
- Ausências, duplicidades e outliers foram tratados de forma conservadora para evitar perda ou fabricação de informação.

18. RELAÇÃO DOS RESULTADOS COM O PROBLEMA E O MVP

A EDA reforça a decisão de incluir a função do trabalhador entre as variáveis relevantes para futuras estimativas de custo. As diferenças observadas entre ocupações e entre divisões CNAE mostram que os valores de remuneração não devem ser representados por um único valor médio para todo o setor, pois variam conforme a ocupação e o segmento de atividade.

A RAIS pode servir como referência externa do mercado formal da construção no Maranhão e apoiar a seleção de variáveis, a definição de faixas de remuneração e a compreensão da composição da mão de obra. Entretanto, ela não contém a granularidade operacional necessária para prever diretamente os pagamentos da Conserpav.

Para o modelo futuro do MVP, o histórico próprio do sistema deverá reunir, por ciclo e por obra, quantidade de trabalhadores, função, valor da diária, dias completos, meias diárias, ausências, duração da obra, pagamentos realizados e custos anteriores. Esse conjunto será mais aderente ao objetivo de estimar o custo do próximo fechamento.

19. LIMITAÇÕES E DECISÕES DO PROJETO

A análise utiliza somente o ano-base 2023 e vínculos formais da construção no Maranhão. Não representa mão de obra informal, trabalhadores pagos por diária avulsa ou a realidade específica das obras da Conserpav. A remuneração média da RAIS é mensal e declarada pelo empregador, não correspondendo diretamente ao valor de uma diária.

A anonimização impede identificar trabalhadores ou obras individualmente. A ausência de uma chave única também limita a interpretação das duplicidades. Além disso, códigos como CNAE, CBO, natureza jurídica e tipos de vínculo dependem de tabelas de domínio para interpretação.

Essas limitações não alteram o problema central nem o MVP. Elas delimitam o papel da RAIS como referência setorial e reforçam a necessidade de construir uma base própria do sistema para futuras etapas de modelagem.

20. CONCLUSÃO DA TED 02

A TED 02 consolidou a preparação do recorte RAIS 2023 utilizado pelo projeto. A base original, com 97.971 registros e 67 atributos, foi inspecionada quanto a estrutura, tipos, valores ausentes, duplicidades, inconsistências e outliers. Após decisões de tratamento justificadas, a base final permaneceu com os mesmos 97.971 registros e passou a possuir 55 colunas.

A limpeza preservou valores cuja remoção ou imputação não poderia ser sustentada pelos dados, incluindo duplicidades, remunerações iguais a zero, outliers e nulos estruturalmente explicáveis. A análise exploratória mostrou diferenças relevantes de remuneração entre segmentos CNAE e ocupações, além de forte assimetria na distribuição salarial.

Os resultados sustentam o uso da RAIS como referência externa para compreender o mercado formal da construção no Maranhão e para orientar a seleção de variáveis do projeto. Para uma previsão diretamente aplicável à Conserpav, a etapa seguinte dependerá do histórico operacional produzido pelo próprio sistema.

21. REFERÊNCIAS

BASE DOS DADOS. Relação Anual de Informações Sociais (RAIS). Disponível em: https://basedosdados.org/dataset/3e7c4d58-96ba-448e-b053-d385a829ef00?table=86b69f96-0bfe-45da-833b-6edc9a0af213. Acesso em: 26 set. 2026

BRASIL. Ministério do Trabalho e Emprego. Microdados RAIS e CAGED. Brasília, DF: Ministério do Trabalho e Emprego. Disponível em: https://www.gov.br/trabalho-e-emprego/pt-br/assuntos/estatisticas-trabalho/microdados-rais-e-caged. Acesso em: 26 set. 2026.

CONSERPAV BIG DATA. CONSERPAV-BIG-DATA. GitHub, 2026. Disponível em: https://github.com/CarlosOliveira7/CONSERPAV-BIG-DATA. Acesso em: 26 set. 2026.