ANDREI PEREIRA LIMA
CARLOS OLIVEIRA LOPES
KAIO MOREIRA MORAIS
PRISCILA FERREIRA DIAS
YWD RHAVELL FERREIRA CARVALHO

TED 03 - MODELAGEM PREDITIVA E MACHINE LEARNING

BALSAS
2026

SUMÁRIO:

TED 01 – Definição do Problema de Dados e Seleção do Conjunto de Dados..... 3
1. PROBLEMA DO PROJETO..... 3
2. DESCRIÇÃO DA SOLUÇÃO E MVP..... 3
2.1 FUNCIONALIDADES DO MVP..... 4
3. NECESSIDADES DE DADOS DA SOLUÇÃO..... 4
4. PESQUISA E COMPARAÇÃO DE CONJUNTOS DE DADOS..... 5
5. CONJUNTO DE DADOS SELECIONADO..... 5
6. PRINCIPAIS ATRIBUTOS / VARIÁVEIS..... 5
7. QUANTIDADE DE REGISTROS..... 5
8. FORMATO DOS DADOS..... 6
9. AVALIAÇÃO PRELIMINAR DA QUALIDADE DOS DADOS (TED 01)..... 6
10. JUSTIFICATIVA DA ESCOLHA DA BASE DE DADOS..... 6
11. RELAÇÃO ENTRE OS DADOS, O PROBLEMA E AS LIMITAÇÕES..... 6
TED 02 — LIMPEZA, SANEAMENTO E ANÁLISE EXPLORATÓRIA..... 7
12. INSPEÇÃO DA ESTRUTURA E DOS TIPOS DE DADOS..... 7
13. ANÁLISE DA QUALIDADE DOS DADOS..... 7
13.1 Valores ausentes..... 7
13.2 Duplicidades..... 7
13.3 Inconsistências identificadas..... 8
13.4 Remunerações iguais a zero..... 8
13.5 Valores atípicos..... 8
14. TRATAMENTOS E JUSTIFICATIVAS..... 8
15. DESCRIÇÃO DA BASE APÓS O TRATAMENTO..... 9
16. ANÁLISE EXPLORATÓRIA DOS DADOS..... 9
16.1 Estatísticas descritivas..... 9
16.2 Distribuição da remuneração..... 10
16.3 Remuneração por divisão CNAE..... 10
16.4 Ocupações mais frequentes..... 11
16.5 Remuneração por ocupação..... 12
16.6 Situação dos vínculos em 31/12..... 13
17. PRINCIPAIS PADRÕES E RELAÇÕES IDENTIFICADOS..... 13
18. RELAÇÃO DOS RESULTADOS COM O PROBLEMA E O MVP..... 13
19. LIMITAÇÕES E DECISÕES DO PROJETO..... 14
20. CONCLUSÃO DA TED 02..... 14
TED 03 – MODELAGEM PREDITIVA E MACHINE LEARNING..... 14
21 DEFINIÇÃO DO PROBLEMA DE MACHINE LEARNING..... 14
22 TIPO DE ABORDAGEM E VARIÁVEL-ALVO..... 15
22.1 Abordagem adotada..... 15
22.2 Variável-alvo..... 15
23 PREPARAÇÃO DOS DADOS..... 15
23.1 Etapas de preparação..... 15
23.2 Alterações em relação à TED 02..... 16

24 SELEÇÃO DE VARIÁVEIS..... 17
25 TÉCNICAS UTILIZADAS E JUSTIFICATIVA..... 18
26 PROCESSO DE TREINAMENTO E AVALIAÇÃO..... 18
26.1 Divisão dos dados..... 18
26.2 Verificação de generalização..... 18
27 MÉTRICAS DE AVALIAÇÃO..... 19
28 RESULTADOS OBTIDOS..... 19
28.1 Comparação com o baseline..... 19
28.2 Erro por faixa de remuneração..... 20
28.3 Valores reais e previstos e resíduos..... 20
28.4 IMPORTÂNCIA DAS VARIÁVEIS..... 21
29 INTERPRETAÇÃO DOS RESULTADOS..... 22
30 LIMITAÇÕES IDENTIFICADAS..... 22
31 RELAÇÃO COM O PROJETO E COM O MVP..... 23
32 REGISTRO DE DECISÕES E PRÓXIMOS EXPERIMENTOS..... 24
33 CONCLUSÃO DA TED 03..... 25
REFERÊNCIAS..... 25

TED 01 – Definição do Problema de Dados e Seleção do Conjunto de Dados

Este documento preserva o problema, a solução, o MVP, a seleção do conjunto de dados e as limitações identificadas na TED 01 e acrescenta os resultados da etapa de limpeza, saneamento, preparação e análise exploratória da RAIS 2023. A versão registra as decisões tomadas sobre valores ausentes, duplicidades, inconsistências, valores atípicos e atributos irrelevantes, descreve a base pós-tratamento e interpreta os principais padrões encontrados em relação ao problema da Conserpav.

1. PROBLEMA DO PROJETO

O projeto tem como cliente a Conserpav, empresa voltada ao setor de obras e pavimentação. O problema central é o controle de presença e o fechamento de pagamento dos trabalhadores, atividades ainda realizadas de forma predominantemente manual, com cadernos, anotações e planilhas.

No canteiro, o responsável registra a frequência diária, verifica quem trabalhou o período completo, meio período ou faltou e, posteriormente, cruza essas informações para calcular os pagamentos. Esse processo favorece erros de soma, perda de informações, retrabalho e dificuldade para recuperar o histórico. Como os ciclos de pagamento podem ser semanais ou quinzenais, o acompanhamento histórico dos custos de mão de obra também se torna difícil.

A solução proposta busca centralizar esses registros, simplificar o cálculo dos pagamentos e aproveitar o histórico gerado nas obras para aumentar a previsibilidade financeira dos períodos seguintes.

2. DESCRIÇÃO DA SOLUÇÃO E MVP

A proposta consiste em um sistema web inteligente para gestão de frequência, cálculo de pagamentos e projeção de custos com mão de obra. A plataforma deverá registrar a presença diária, calcular automaticamente os valores devidos e consolidar o histórico financeiro dos canteiros.

Como diferencial, o sistema prevê um componente de Inteligência Artificial para analisar o histórico e estimar os custos de pessoal do próximo ciclo de fechamento. A projeção deverá considerar, entre outras, as seguintes variáveis:

- Quantidade de trabalhadores alocados;
- Valores estipulados para as diárias;
- Média de dias efetivamente trabalhados;
- Ocorrência de jornadas parciais (meias diárias);
- Despesas consolidadas em períodos anteriores;
- Comportamento macro dos gastos na obra.

A previsão terá caráter estimativo e funcionará como apoio analítico à tomada de decisão, preservando a autonomia do gestor.

2.1 FUNCIONALIDADES DO MVP

Cadastro de obras, com definição do ciclo de fechamento semanal ou quinzenal.
Cadastro de funcionários, incluindo nome, função, valor da diária, obra vinculada e chave Pix.

Registro de frequência, distinguindo diária completa, meia diária e ausência.
Cálculo automático de pagamentos a partir dos apontamentos de frequência.

Histórico de presença e pagamentos de ciclos anteriores.
Relatório de pagamento com dias completos, meios dias, faltas, valor total e chave Pix.
Previsão de custos com IA, exibindo custo estimado, custo anterior, média histórica e variação estimada.

3. NECESSIDADES DE DADOS DA SOLUÇÃO

Com base no problema identificado e nas funcionalidades do MVP, as principais necessidades de dados são:

Necessidade de dados	Utilização no projeto
Identificação da obra	Associar os registros ao projeto correspondente
Identificação do trabalhador	Associar frequência e pagamentos ao funcionário
Função do trabalhador	Analisar a composição da mão de obra
Valor da diária / remuneração	Calcular e analisar o pagamento
Data / admissão / desligamento	Organizar frequência e vínculo ao longo do tempo
Situação da frequência	Identificar diária completa, meia diária ou ausência
Quantidade de trabalhadores	Avaliar a demanda de mão de obra
Duração da obra / vínculo	Relacionar duração e necessidade de recursos
Custo da obra / folha	Analisar o comportamento dos custos
Histórico de custos	Apoiar a previsão de custos futuros

4. PESQUISA E COMPARAÇÃO DE CONJUNTOS DE DADOS

As alternativas pesquisadas em repositórios públicos, como o Kaggle, apresentaram baixa aderência ao problema: algumas tratavam de qualidade ou segurança de obras, outras eram simuladas e outras pertenciam a setores ou contextos geográficos diferentes. Nenhuma reunia, de forma satisfatória, variáveis reais de frequência, remuneração ou custo de mão de obra da construção civil.

A equipe optou, portanto, pelos microdados de vínculos da RAIS (Relação Anual de Informações Sociais), disponibilizados pelo Ministério do Trabalho e Emprego. O CAGED foi considerado durante a pesquisa, mas não é utilizado nesta etapa.

5. CONJUNTO DE DADOS SELECIONADO

A base escolhida corresponde aos microdados de vínculos da RAIS, ano-base 2023, registro administrativo do mercado de trabalho formal brasileiro mantido pelo Ministério do Trabalho e Emprego (MTE/PDET). Os registros são públicos e não identificados.

Para evitar o processamento dos arquivos nacionais completos, a equipe utilizou a RAIS estruturada pela Base dos Dados no BigQuery. O recorte selecionou o Maranhão, o ano de 2023 e as divisões 41, 42 e 43 da CNAE 2.0, correspondentes às atividades de construção. O resultado foi exportado em CSV.

Consulta utilizada:

```
SELECT *
FROM `basedosdados.br_me_rais.microdados_vinculos`
```

```
WHERE ano = 2023
  AND sigla_uf = 'MA'
  AND SUBSTR(cnae_2, 1, 2) IN ('41', '42', '43')
```

6. PRINCIPAIS ATRIBUTOS / VARIÁVEIS

1. Setor e função: cnae_2 e cbo_2002.
2. Remuneração: valor_remuneracao_media, valor_remuneracao_media_sm e remunerações mensais de janeiro a dezembro.
3. Vínculo e tempo: mes_admissao, mes_desligamento, tempo_emprego, vinculo_ativo_3112 e tipo_vinculo.
4. Jornada: quantidade_horas_contratadas e indicador_trabalho_parcial.
5. Localização e porte: id_municipio, sigla_uf e tamanho_estabelecimento.
6. Perfil do trabalhador: sexo, idade, grau_instrucao_apos_2005 e raca_cor.
7. Referência temporal: ano.

7. QUANTIDADE DE REGISTROS

A RAIS 2023 possui 82.966.522 registros em âmbito nacional. O recorte do Maranhão possui 1.265.961 registros. Após o filtro das divisões 41, 42 e 43 da CNAE 2.0, a base utilizada no projeto ficou com 97.971 registros e 67 atributos.

Divisão CNAE	Descrição	Vínculos	Participação
41	Construção de edifícios	50.096	51,13%
42	Obras de infraestrutura	34.148	34,86%
43	Serviços especializados para construção	13.727	14,01%

8. FORMATO DOS DADOS

Os dados são disponibilizados originalmente pelo MTE em arquivos de texto delimitados por ponto e vírgula. Para o projeto, o recorte foi consultado via SQL na Base dos Dados (BigQuery) e exportado em CSV, facilitando a leitura em Python/Pandas e a posterior preparação dos dados.

9. AVALIAÇÃO PRELIMINAR DA QUALIDADE DOS DADOS (TED 01)

A avaliação preliminar identificou 58 das 67 colunas sem valores ausentes e nove colunas com nulos. Cinco estavam 100% vazias: tipo_salario, valor_salario_contratual, subatividade_ibge, cbo_1994 e grau_instrucao_1985_2005. id_municipio_trabalho possuía 99,97% de nulos; motivo_desligamento, 51,33%; valor_remuneracao_dezembro, 53,73%; e natureza_juridica, 29,78%.

Também foram identificados 542 registros duplicados (0,55%), 11.840 vínculos com valor_remuneracao_media igual a zero e uma distribuição de remuneração fortemente assimétrica à direita. A TED 01 registrou essas ocorrências como pontos a investigar antes de qualquer remoção ou substituição.

10. JUSTIFICATIVA DA ESCOLHA DA BASE DE DADOS

A RAIS foi escolhida por ser uma fonte real, oficial e verificável, com remuneração declarada, ocupação, setor, localização e informações temporais dos vínculos formais. O volume de 97.971 vínculos no recorte é suficiente para análises estatísticas e exploratórias.

A base não reproduz o registro diário de frequência da Conserpav, mas fornece uma referência setorial útil para estudar remuneração, ocupação e características dos vínculos na construção do Maranhão.

11. RELAÇÃO ENTRE OS DADOS, O PROBLEMA E AS LIMITAÇÕES

As necessidades do projeto são parcialmente atendidas pela RAIS. A função é aproximada por cbo_2002; a composição da mão de obra pode ser analisada por CNAE e ocupação; a remuneração média mensal funciona como referência de custo; e a duração do vínculo é aproximada por tempo_emprego e pelos meses de admissão e desligamento.

A aderência não é completa. A RAIS trabalha com estabelecimentos, não com obras; não identifica nominalmente trabalhadores; não possui frequência diária, diárias completas/meias diárias ou histórico de pagamentos individuais; cobre apenas vínculos formais; e a remuneração declarada é mensal, não uma diária. Por isso, seus padrões devem ser interpretados como referência do setor, e não como retrato das obras da Conserpav.

O histórico gerado pelo próprio sistema será necessário para uma previsão futura com granularidade operacional, incluindo obra, trabalhador, função, diária, frequência e valor pago.

TED 02 — LIMPEZA, SANEAMENTO E ANÁLISE EXPLORATÓRIA

A TED 02 dá continuidade à etapa anterior e utiliza o mesmo recorte da RAIS 2023: 97.971 vínculos do setor da construção no Maranhão, com 67 atributos na base original. A análise foi realizada em Python/Pandas e documentada no notebook do projeto.

12. INSPEÇÃO DA ESTRUTURA E DOS TIPOS DE DADOS

A base original possui 97.971 linhas e 67 colunas. Na leitura pelo Pandas, foram observados 42 atributos inteiros, 24 atributos de ponto flutuante e uma variável textual. Diversas colunas numéricas representam códigos categóricos, como tipo_vinculo, cbo_2002, cnae_2 e tipo_estabelecimento; portanto, não devem ser interpretadas como medidas contínuas apenas por estarem armazenadas como números.

motivo_desligamento e natureza_juridica aparecem como float64 em razão da presença de valores ausentes, embora conceitualmente sejam códigos categóricos. Não foi realizada conversão em massa dos tipos, pois os formatos existentes são adequados ao processamento e as variáveis foram tratadas conforme seu significado na análise.

13. ANÁLISE DA QUALIDADE DOS DADOS

13.1 Valores ausentes

Variável	Nulos	Percentual
tipo_salario	97.971	100,00%
valor_salario_contratual	97.971	100,00%
subatividade_ibge	97.971	100,00%
cbo_1994	97.971	100,00%

grau_instrucao_1985_2005	97.971	100,00%
id_municipio_trabalho	97.944	99,97%
valor_remuneracao_dezembro	52.637	53,73%
motivo_desligamento	50.289	51,33%
natureza_juridica	29.172	29,78%

A investigação mostrou que os 50.289 nulos em motivo_desligamento coincidem com mes_desligamento igual a zero, caracterizando vínculos sem desligamento registrado. Esses nulos foram mantidos, pois possuem significado estrutural e não representam necessariamente falha de preenchimento.

Em valor_remuneracao_dezembro, 52.637 registros estão ausentes. A ausência é fortemente associada a vínculos inativos, mas também existem 6.596 vínculos ativos sem valor de dezembro. Como não há evidência para substituir esses casos por zero ou por outro valor, os nulos foram preservados. A Natureza_juridica possui 29.172 nulos (29,78%), concentrados principalmente no tipo_estabelecimento 6. Como a variável possui 15 códigos observados e 70,22% de preenchimento, ela foi mantida sem imputação.

13.2 Duplicidades

Na base original foram encontradas 542 ocorrências duplicadas (0,55%). Como os microdados são anonimizados e não possuem identificador único de trabalhador ou vínculo, linhas com os mesmos 67 atributos podem corresponder a vínculos distintos. Assim, nenhuma linha foi removida por duplicidade.

Após a retirada de atributos, a base tratada passou a apresentar 543 ocorrências duplicadas. O aumento de uma ocorrência é esperado porque a remoção de colunas pode tornar idênticas linhas que antes diferiam em algum atributo descartado. A decisão de preservação foi mantida.

13.3 Inconsistências identificadas

Foram encontrados dois registros com vinculo_ativo_3112 igual a 0, mes_desligamento igual a 0 e motivo_desligamento igual a 11, além de causas de desligamento codificadas como 999. Esses dois casos representam aproximadamente 0,002% da base. Como não existe informação suficiente para inferir o mês correto ou corrigir os códigos, os registros foram preservados e a inconsistência foi documentada.

A variável quantidade_horas_contratadas também contém códigos extremos, incluindo 0 e 99. Como o valor 99 aparece em 3.920 registros e pode refletir codificação específica da fonte, ele não foi alterado nem interpretado literalmente na EDA sem confirmação de domínio.

13.4 Remunerações iguais a zero

Foram identificados 11.840 vínculos (12,09%) com valor_remuneracao_media igual a zero. Desses, 6.827 estavam inativos e 5.013 ativos em 31/12. A inspeção das remunerações mensais mostrou que parte desses vínculos possui valores positivos em meses específicos. Portanto, zero não foi convertido em nulo nem utilizado como critério de exclusão.

Para análises especificamente voltadas à distribuição de remuneração, foram calculadas estatísticas adicionais considerando apenas valores positivos, sem alterar a base tratada.

13.5 Valores atípicos

Pelo método do intervalo interquartil (IQR), Q1 = R$1.302,00, Q3 = R$2.621,245 e IQR = R$1.319,245. O limite superior calculado foi R$4.600,1125 e 5.159 registros (5,27%) ficaram acima ou fora dos limites estatísticos.

Os outliers não foram removidos nem winsorizados. A maior remuneração média observada foi R$72.837,96. Como remunerações elevadas podem corresponder a cargos e vínculos reais, um valor estatisticamente atípico não foi tratado automaticamente como erro. Nos gráficos, foram utilizados limites de visualização quando necessário, preservando todas as observações na base.

14. TRATAMENTOS E JUSTIFICATIVAS

A limpeza foi conservadora: foram removidos atributos sem informação útil ou sem aplicabilidade ao recorte, enquanto linhas e valores potencialmente legítimos foram preservados.

Tratamento	Decisão e justificativa
5 colunas 100% vazias	Removidas por não conterem informação no recorte.
5 colunas de localidades fora do Maranhão	Removidas por não serem aplicáveis ao recorte geográfico.
ano_chegada_brasil	Removida por apresentar valor constante no recorte.
id_municipio_trabalho	Removida por possuir 99,97% de valores ausentes; id_municipio permanece disponível.
ano e sigla_uf	Mantidas para contexto e rastreabilidade, embora constantes no recorte.
motivo_desligamento	Nulos mantidos por representarem predominantemente ausência de desligamento.
valor_remuneracao_dezembro	Nulos mantidos; não há base segura para imputação.
natureza_juridica	Mantida sem imputação; variável possui informação em 70,22% dos registros.
Duplicidades	Mantidas devido à anonimização e ausência de chave única.
Remuneração média zero	Mantida após verificação de valores mensais positivos em parte dos casos.
Outliers de remuneração	Mantidos por não haver evidência de erro.

Ao final, foram removidas 12 colunas e nenhuma linha.

15. DESCRIÇÃO DA BASE APÓS O TRATAMENTO

Indicador	Resultado
Registros	97.971
Colunas	55
Linhas removidas	0

Colunas removidas	12
Colunas com valores ausentes	3
Valores ausentes remanescentes	132.098
Duplicados na base tratada	543
Remuneração média igual a zero	11.840

Os valores ausentes remanescentes concentram-se em valor_remuneracao_dezembro, motivo_desligamento e natureza_juridica e foram mantidos de forma consciente e documentada. A base tratada foi exportada como data/processed/rais_ma_construcao_2023_tratada.csv.

16. ANÁLISE EXPLORATÓRIA DOS DADOS

16.1 Estatísticas descritivas

Variável	Média	Mediana	Mínimo	Máximo
Idade	37,74	37	15	85
Horas contratadas	45,74	44	0	99
Tempo de emprego	18,59	8,3	0	476,9
Remuneração média (R$)	2.074,61	1.833,48	0	72.837,96

Entre os 86.131 vínculos com remuneração média positiva, a média foi R$2.359,80, a mediana R$1.971,00 e o desvio-padrão R$1.685,26. Considerando todos os registros, a média foi R$2.074,61, a mediana R$1.833,48 e o desvio-padrão R$1.757,42.

16.2 Distribuição da remuneração

A distribuição é assimétrica à direita: a média supera a mediana e existe uma cauda formada por remunerações mais altas. Para tornar o histograma legível, a visualização foi limitada ao percentil 99 das remunerações positivas, equivalente a R$8.830,38. Esse limite foi aplicado apenas ao gráfico; os valores superiores continuam na base.

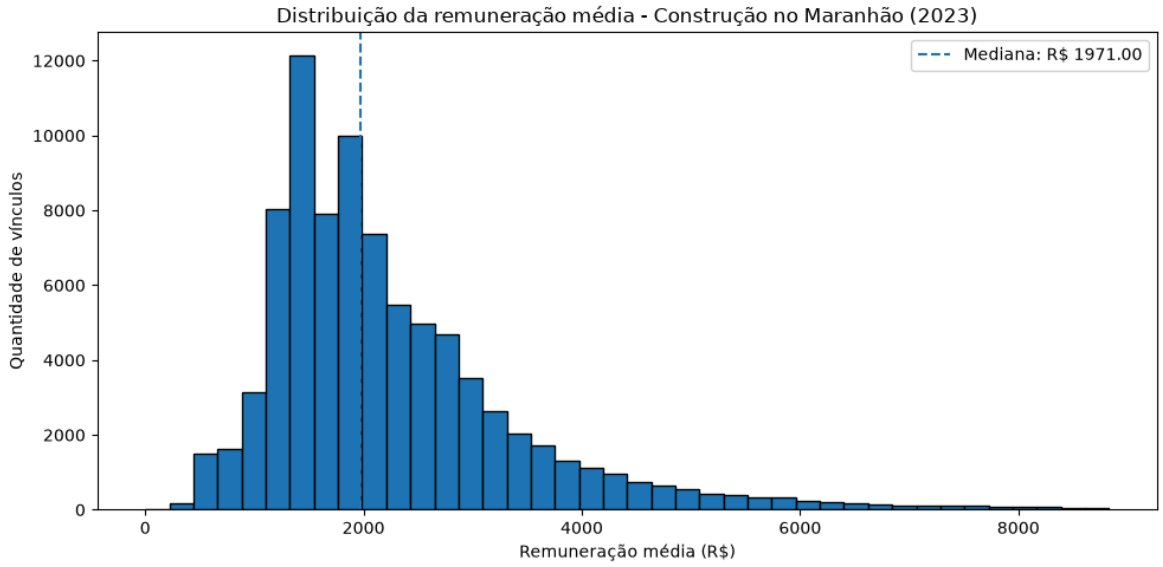


Figura 1 — Distribuição da remuneração média positiva até o percentil 99.

16.3 Remuneração por divisão CNAE

Divisão	Vínculos com remuneração positiva	Média (R$)	Mediana (R$)
41 — Construção de edifícios	42.712	1.965,71	1.750,58
42 — Obras de infraestrutura	31.373	2.863,59	2.520,02
43 — Serviços especializados	12.046	2.445,06	1.961,00

A divisão 42 apresenta a maior remuneração mediana entre as três divisões. A diferença sugere que o segmento de atividade deve ser considerado na interpretação dos custos de mão de obra, especialmente porque obras de infraestrutura possuem proximidade com o contexto de pavimentação da Conserpav.

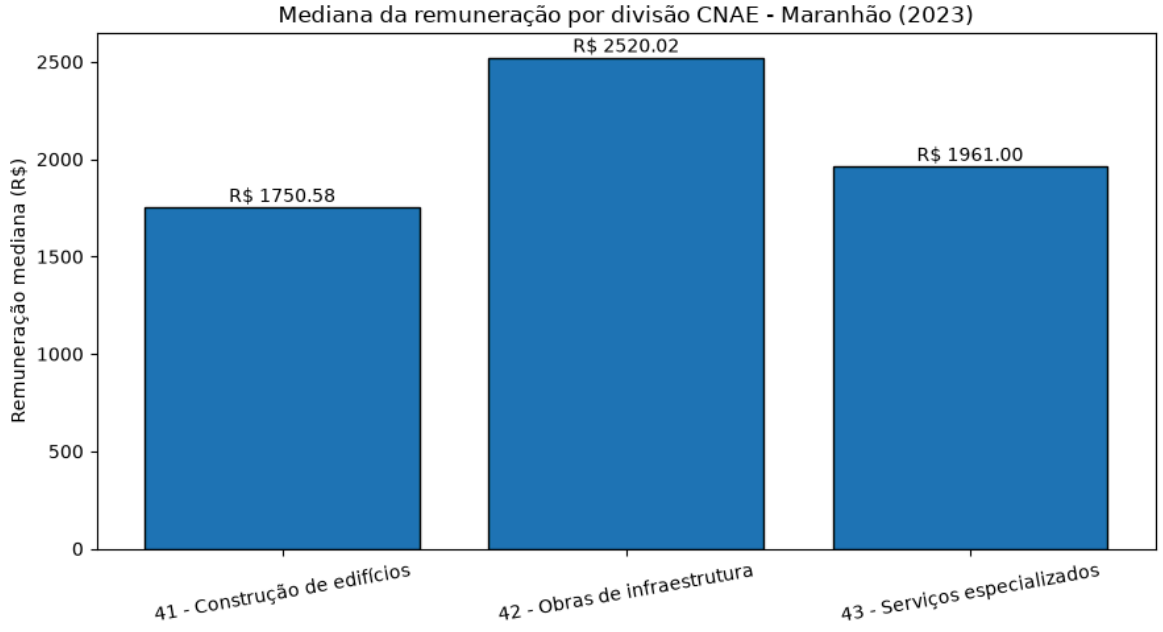


Figura 2 — Remuneração mediana por divisão CNAE.

16.4 Ocupações mais frequentes

CBO	Ocupação	Vínculos
717020	Servente de obras	21.685
715210	Pedreiro	10.697
715615	Eletricista de instalações	3.436
782510	Motorista de caminhão	3.183
710205	Mestre de construção civil	2.247
517420	Vigia	2.107
411005	Auxiliar de escritório	1.938
411010	Assistente administrativo	1.787
715505	Carpinteiro	1.659

724205	Montador de estruturas metálicas	1.606

Serventes de obras e pedreiros concentram as maiores frequências entre as ocupações destacadas, evidenciando o peso das funções operacionais no recorte.

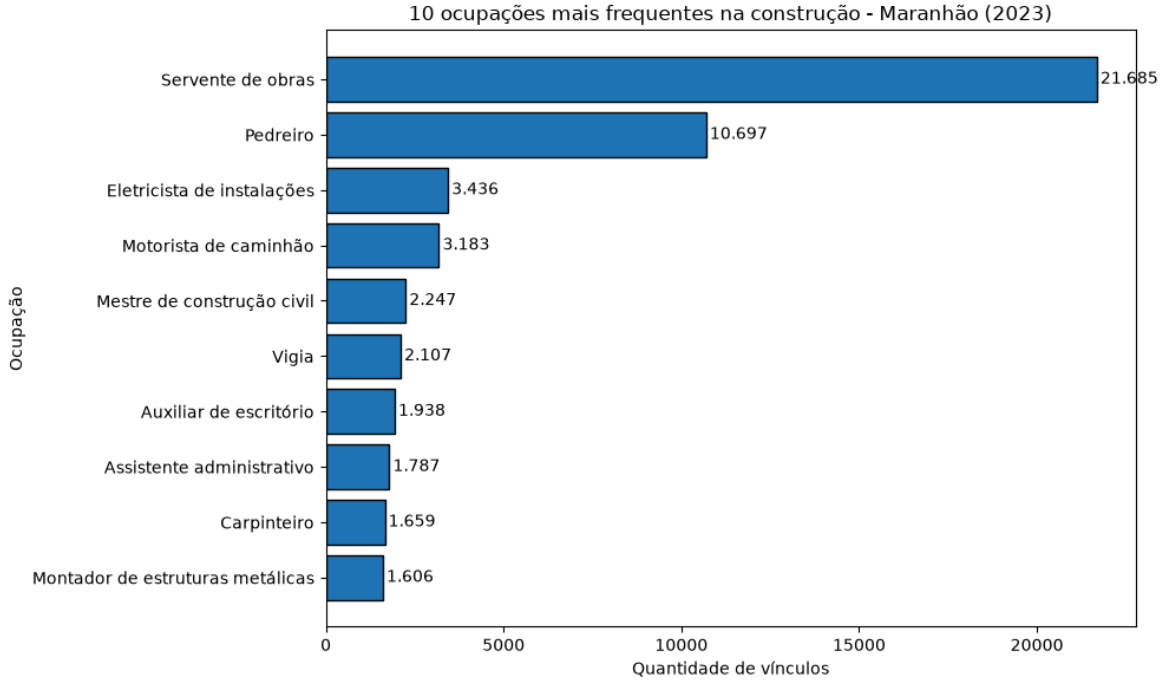


Figura 3 — Dez ocupações mais frequentes no recorte analisado.

16.5 Remuneração por ocupação

Ocupação	Vínculos positivos	Média (R$)	Mediana (R$)
Mestre de construção civil	2.041	3.805,61	3.418,13
Eletricista de instalações	3.131	2.507,15	2.630,29
Motorista de caminhão	2.843	2.697,29	2.609,73
Carpinteiro	1.454	2.043,38	1.973,40
Montador de estruturas metálicas	1.472	1.980,13	1.953,48
Pedreiro	9.081	1.973,80	1.945,23
Assistente administrativo	1.620	2.007,63	1.700,00
Vigia	1.807	1.727,40	1.665,35
Auxiliar de escritório	1.730	1.623,24	1.470,95
Servente de obras	18.633	1.447,01	1.394,80

Entre as dez ocupações mais frequentes, a remuneração mediana varia de R$1.394,80 para Servente de obras a R$3.418,13 para Mestre de construção civil. A amplitude observada reforça a relevância da função/ocupação como variável explicativa para análises de custo.

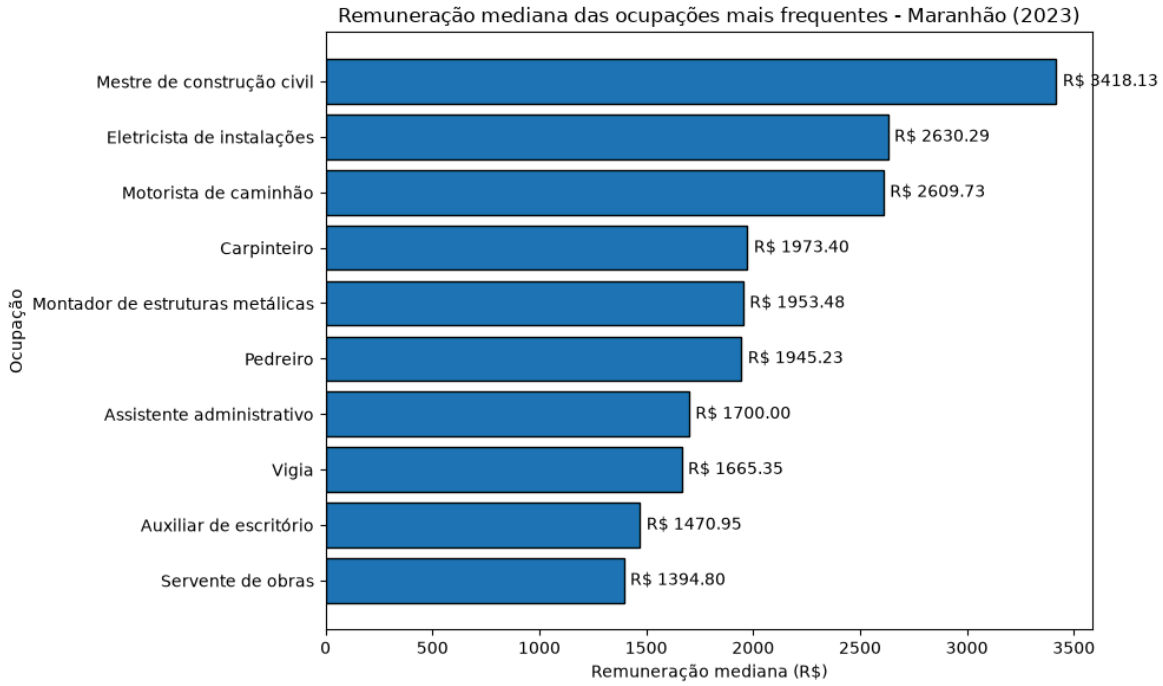


Figura 4 — Remuneração mediana das ocupações mais frequentes.

16.6 Situação dos vínculos em 31/12

Em 31/12, 50.378 vínculos estavam ativos (51,42%) e 47.593 inativos (48,58%). O equilíbrio entre os grupos ajuda a contextualizar a presença de valores ausentes em variáveis de desligamento e em remuneração de dezembro.

17. PRINCIPAIS PADRÕES E RELAÇÕES IDENTIFICADOS

- A remuneração apresenta assimetria à direita; por isso, média e mediana devem ser analisadas em conjunto.
- Os 11.840 valores médios iguais a zero exigem interpretação cuidadosa e não devem ser tratados automaticamente como erros.
- A divisão CNAE 42 apresentou maior remuneração mediana entre as divisões 41, 42 e 43.
- As ocupações apresentam diferenças relevantes de remuneração, com destaque para a distância entre serventes e mestres de construção civil.
- A situação ativo/inativo está praticamente equilibrada no final do ano, aspecto importante para interpretar desligamentos e remuneração de dezembro.
- Ausências, duplicidades e outliers foram tratados de forma conservadora para evitar perda ou fabricação de informação.

18. RELAÇÃO DOS RESULTADOS COM O PROBLEMA E O MVP

A EDA reforça a decisão de incluir a função do trabalhador entre as variáveis relevantes para futuras estimativas de custo. As diferenças observadas entre ocupações e entre divisões CNAE mostram que os valores de remuneração não devem ser representados por um único valor médio para todo o setor, pois variam conforme a ocupação e o segmento de atividade.

A RAIS pode servir como referência externa do mercado formal da construção no Maranhão e apoiar a seleção de variáveis, a definição de faixas de remuneração e a

compreensão da composição da mão de obra. Entretanto, ela não contém a granularidade operacional necessária para prever diretamente os pagamentos da Conserpav.

Para o modelo futuro do MVP, o histórico próprio do sistema deverá reunir, por ciclo e por obra, quantidade de trabalhadores, função, valor da diária, dias completos, meias diárias, ausências, duração da obra, pagamentos realizados e custos anteriores. Esse conjunto será mais aderente ao objetivo de estimar o custo do próximo fechamento.

19. LIMITAÇÕES E DECISÕES DO PROJETO

A análise utiliza somente o ano-base 2023 e vínculos formais da construção no Maranhão. Não representa mão de obra informal, trabalhadores pagos por diária avulsa ou a realidade específica das obras da Conserpav. A remuneração média da RAIS é mensal e declarada pelo empregador, não correspondendo diretamente ao valor de uma diária.

A anonimização impede identificar trabalhadores ou obras individualmente. A ausência de uma chave única também limita a interpretação das duplicidades. Além disso, códigos como CNAE, CBO, natureza jurídica e tipos de vínculo dependem de tabelas de domínio para interpretação.

Essas limitações não alteram o problema central nem o MVP. Elas delimitam o papel da RAIS como referência setorial e reforçam a necessidade de construir uma base própria do sistema para futuras etapas de modelagem.

20. CONCLUSÃO DA TED 02

A TED 02 consolidou a preparação do recorte RAIS 2023 utilizado pelo projeto. A base original, com 97.971 registros e 67 atributos, foi inspecionada quanto a estrutura, tipos, valores ausentes, duplicidades, inconsistências e outliers. Após decisões de tratamento justificadas, a base final permaneceu com os mesmos 97.971 registros e passou a possuir 55 colunas.

A limpeza preservou valores cuja remoção ou imputação não poderia ser sustentada pelos dados, incluindo duplicidades, remunerações iguais a zero, outliers e nulos estruturalmente explicáveis. A análise exploratória mostrou diferenças relevantes de remuneração entre segmentos CNAE e ocupações, além de forte assimetria na distribuição salarial.

Os resultados sustentam o uso da RAIS como referência externa para compreender o mercado formal da construção no Maranhão e para orientar a seleção de variáveis do projeto. Para uma previsão diretamente aplicável à Conserpav, a etapa seguinte dependerá do histórico operacional produzido pelo próprio sistema.

TED 03 – MODELAGEM PREDITIVA E MACHINE LEARNING

A TED 03 dá continuidade às etapas anteriores e aplica técnicas de Machine Learning à base preparada na TED 02. Os experimentos foram implementados em Python, com as bibliotecas Pandas (MCKINNEY, 2010) e scikit-learn (PEDREGOSA et al., 2011), e estão documentados no notebook projeto/src/TED03.ipynb do repositório do projeto.

21 DEFINIÇÃO DO PROBLEMA DE MACHINE LEARNING

O problema de Machine Learning tratado é estimar a remuneração média mensal, em reais, de um vínculo formal de trabalho na construção civil do Maranhão a partir da ocupação, do setor, do perfil do trabalhador, da jornada contratada e do porte do estabelecimento.

A escolha decorre das etapas anteriores. A TED 01 previu, no MVP, uma funcionalidade de Inteligência Artificial para estimar o custo de mão de obra do próximo período e indicou a avaliação de modelos de regressão com scikit-learn. A TED 02 mostrou que a remuneração é assimétrica à direita e varia fortemente por ocupação (mediana de R$ 1.394,80 para servente de obras a R$ 3.418,13 para mestre de construção civil) e por divisão CNAE (mediana de R$ 1.750,58 na divisão 41 a R$ 2.520,02 na divisão 42). Esses padrões indicam que ocupação e setor devem ser preditores do modelo.

A RAIS não contém frequência diária, valor de diária nem identificação de obra. Por essa razão, o modelo funciona como referência salarial do setor por função e perfil, e não como previsão do custo de mão de obra da Conserpav. Essa diferença é retomada nas seções de limitações e de relação com o MVP.

22 TIPO DE ABORDAGEM E VARIÁVEL-ALVO

22.1 Abordagem adotada

Adotou-se a regressão supervisionada, porque o objetivo é prever um valor numérico contínuo em reais e a base traz o valor real de cada vínculo, o que permite treinar e comparar as previsões. A classificação exigiria discretizar a remuneração em faixas e perderia informação, e o agrupamento (clustering) não produz uma estimativa em reais.

22.2 Variável-alvo

A variável-alvo é valor_remuneracao_media, remuneração média mensal declarada na RAIS 2023. Entre os vínculos utilizados na modelagem, a média é de R$ 2.364,39, a mediana de R$ 1.973,40, o percentil 99 de R$ 8.849,03 e o máximo de R$ 72.837,96, com assimetria de 6,28, o que indica cauda longa à direita.

23 PREPARAÇÃO DOS DADOS

23.1 Etapas de preparação

A preparação reproduz no notebook as decisões da TED 02 e acrescenta as transformações específicas da modelagem. O notebook parte do arquivo projeto/data/base_de_dados.csv, que é o recorte da RAIS 2023 para o Maranhão, e refaz a remoção das 12 colunas, em vez de ler o arquivo tratado citado na seção 15, que não está versionado no repositório. As etapas constam no Quadro 1.

Quadro 1 – Etapas de preparação dos dados para a modelagem

Etapa	Procedimento	Efeito
Carga	Leitura de base_de_dados.csv (codificação latin-1)	97.971 registros e 67 colunas

Remoção de colunas	12 colunas descartadas na TED 02: 5 totalmente vazias, 5 de localidades fora do Maranhão, ano_chegada_brasil e id_municipio_trabalho	55 colunas
Duplicidades	drop_duplicates()	543 registros removidos
Filtro do alvo	Mantidos apenas os vínculos com valor_remuneracao_media > 0	11.673 vínculos excluídos; 85.755 registros
Tipagem	Cinco variáveis categóricas convertidas para texto	Códigos tratados como categorias, e não como quantidades
Codificação	OneHotEncoder(handle_unknown='ignore') nas categóricas	742 colunas de entrada
Imputação	SimpleImputer(strategy='median') nas numéricas	Sem nulos no recorte; protege o uso futuro

Fonte: Elaborado pelos autores (2026).

Todo o pré-processamento foi encapsulado em um ColumnTransformer dentro de um Pipeline, de modo que as transformações são ajustadas apenas com os dados de treino e não vazam informação do conjunto de teste. Não houve normalização, pois a regressão linear ordinária não depende da escala das variáveis.

23.2 Alterações em relação à TED 02

Duas decisões de tratamento da TED 02 foram alteradas exclusivamente para a modelagem; a base original e o registro da TED 02 permanecem inalterados. A primeira é a exclusão dos 11.840 vínculos com remuneração média igual a zero (11.673 após a remoção das duplicidades). A TED 02 os manteve porque parte deles possui valores positivos em meses específicos, mas, sendo o alvo o próprio valor da remuneração, o zero distorce o ajuste do modelo. A segunda é a remoção das 543 duplicidades. A TED 02 as manteve por não haver chave única de vínculo; na modelagem, a remoção evita que linhas idênticas caiam simultaneamente nos conjuntos de treino e de teste.

O efeito dessas decisões foi medido com a mesma divisão de dados e a mesma semente aleatória (Tabela 1). Manter duplicidades e zeros piora o ajuste de forma clara (R^2 de 0,383 contra 0,475). Já a diferença entre manter e remover as duplicidades (R^2 de 0,445 e 0,475) é compatível com a oscilação entre divisões observada na validação cruzada (desvio-padrão de 0,017), de modo que a remoção das duplicidades não altera a conclusão.

Tabela 1 – Efeito das decisões de tratamento sobre o desempenho da regressão linear no conjunto de teste

Cenário	Registros	MAE (R$)	R^2
TED 02 pura: mantém duplicidades e zeros	97.971	779,99	0,383
Mantém duplicidades e exclui zeros	86.131	626,59	0,445
Remove duplicidades e exclui zeros (adotado)	85.755	634,03	0,475

Fonte: Elaborado pelos autores (2026), a partir do notebook TED03.ipynb.

24 SELEÇÃO DE VARIÁVEIS

Foram utilizadas oito variáveis preditoras, cinco categóricas e três numéricas (Quadro 2). A escolha considerou os fatores que, no mercado de trabalho, mais explicam diferenças salariais e que também existem no cadastro de funcionários do MVP (função, perfil e jornada), o que favorece a futura reutilização do modelo.

Quadro 2 – Variáveis preditoras utilizadas na modelagem

Variável	Tipo	Categorias	Justificativa
cbo_2002	Categórica	719	Ocupação do trabalhador; a TED 02 mostrou grande amplitude de remuneração entre ocupações
cnae_2	Categórica	19	Atividade da empresa; a TED 02 mostrou maior mediana na divisão 42
sexo	Categórica	2	Característica do perfil do trabalhador
tamanho_estabelecimento	Categórica	10	Porte da empresa, associado à política salarial
tipo_vinculo	Categórica	15	Regime de contratação
idade	Numérica	–	Aproximação da experiência do trabalhador
quantidade_horas_contratadas	Numérica	–	Jornada semanal contratada (mediana de 44 horas)
tempo_emprego	Numérica	–	Tempo no vínculo, em meses (mediana de 7,9)

Fonte: Elaborado pelos autores (2026), a partir do notebook TED03.ipynb.

As demais variáveis disponíveis na base foram excluídas por não apresentarem relação direta com o objetivo de estimar a remuneração média mensal, por possuírem caráter identificador, apresentarem informações redundantes ou por não estarem contempladas no escopo definido para a modelagem. A seleção priorizou atributos relacionados à ocupação, ao perfil do trabalhador, à jornada e às características do estabelecimento.

25 TÉCNICAS UTILIZADAS E JUSTIFICATIVA

Foram treinados dois modelos sobre o mesmo pré-processamento:

a) DummyRegressor (baseline): prevê sempre a média da remuneração no conjunto de treino e serve de piso de comparação, pois um modelo só é útil se o superar;

b) LinearRegression: regressão linear ordinária do scikit-learn (PEDREGOSA et al., 2011), aplicada às variáveis codificadas.

A regressão linear foi escolhida porque o problema é de regressão com alvo numérico, porque é rápida para cerca de 85 mil registros e, principalmente, porque seus coeficientes são interpretáveis: cada coeficiente indica quantos reais uma categoria ou uma unidade da variável adiciona à remuneração prevista. Isso permite explicar ao usuário por que uma estimativa mudou, o que é desejável em uma ferramenta de apoio à decisão. A TED 01 já previa o uso de modelos de regressão com scikit-learn. O baseline evita concluir que o modelo é bom sem uma referência comparável.

A regressão linear ordinária não possui hiperparâmetros a ajustar. Modelos mais flexíveis, como árvores e ensembles, não foram testados nesta etapa e constam entre os próximos experimentos.

26 PROCESSO DE TREINAMENTO E AVALIAÇÃO

26.1 Divisão dos dados

Os dados foram divididos em 80% para treino (68.604 registros) e 20% para teste (17.151 registros), com semente aleatória fixa (random_state=42) para reprodutibilidade. A divisão é aleatória simples, sem estratificação, por ser o alvo contínuo. O conjunto de teste não participa do ajuste do pré-processamento nem do modelo, e as métricas principais são calculadas nele, evitando que a avaliação se baseie apenas no que o modelo já viu durante o treinamento.

26.2 Verificação de generalização

Os resultados apresentam proximidade entre o desempenho no treinamento, no teste e na validação cruzada, sem evidências expressivas de sobreajuste nos experimentos realizados. Entretanto, essa estabilidade não garante a generalização do modelo para outros períodos, estados ou contextos de contratação, uma vez que a base utilizada contempla apenas os vínculos formais da construção civil do Maranhão em 2023.

Tabela 2 – Desempenho da regressão linear no treino, no teste e na validação cruzada

Verificação	R^2	MAE (R$)

Treino (68.604 registros)	0,524	614,98
Teste (17.151 registros)	0,475	634,03
Validação cruzada, média de 5 partes	0,482 (desvio-padrão de 0,017)	629,79

Fonte: Elaborado pelos autores (2026), a partir do notebook TED03.ipynb.

27 MÉTRICAS DE AVALIAÇÃO

Por se tratar de um problema de regressão, foram utilizadas quatro métricas, calculadas no conjunto de teste e descritas no Quadro 3. Métricas de classificação (acurácia, precisão, F1-score, matriz de confusão) e de agrupamento (silhouette) não se aplicam a este problema.

Quadro 3 – Métricas de avaliação e justificativa de uso

Métrica	O que mede	Justificativa
MAE (R$)	Erro absoluto médio	Está na mesma unidade do alvo e expressa o erro típico de forma direta; é menos sensível a valores extremos
MSE	Erro quadrático médio	Penaliza erros grandes e é a base do RMSE
RMSE (R$)	Raiz do erro quadrático médio	Também em reais; ao ser comparado com o MAE, revela o efeito de valores extremos
R^2	Proporção da variância explicada	Compara o modelo com a simples previsão da média; R^2 igual a zero equivale ao baseline

Fonte: Elaborado pelos autores (2026).

28 RESULTADOS OBTIDOS

28.1 Comparação com o baseline

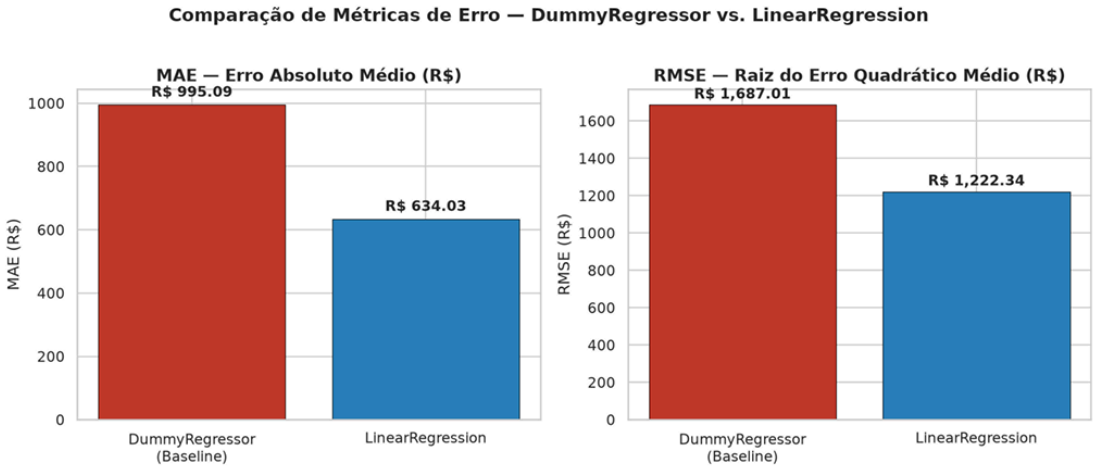
A regressão linear reduziu o MAE de R$ 995,09 para R$ 634,03 (redução de 36,3%) e o RMSE de R$ 1.687,01 para R$ 1.222,34 (redução de 27,5%) em relação ao baseline, no conjunto de teste de 17.151 registros (Tabela 3 e Figura 1).

Tabela 3 – Desempenho dos modelos no conjunto de teste

Modelo	MAE (R$)	MSE	RMSE (R$)	R^2
DummyRegressor (baseline)	995,09	2.846.010,87	1.687,01	0,000
LinearRegression	634,03	1.494.122,98	1.222,34	0,475

Fonte: Elaborado pelos autores (2026), a partir do notebook TED03.ipynb.

Figura 1 – Comparação de MAE e RMSE entre o baseline e a regressão linear



Fonte: Elaborado pelos autores (2026), a partir do notebook TED03.ipynb.

28.2 Erro por faixa de remuneração

O erro não é uniforme ao longo da distribuição (Tabela 4). O erro absoluto mediano é de R$ 373,94, o que corresponde a 18,8% do valor real, e 41,8% das previsões ficam a até R$ 300 do valor real. Oito previsões resultaram negativas (mínimo de R$ −780,73), pois a regressão linear não limita a saída.

Tabela 4 – Erro da regressão linear por faixa de remuneração real no conjunto de teste

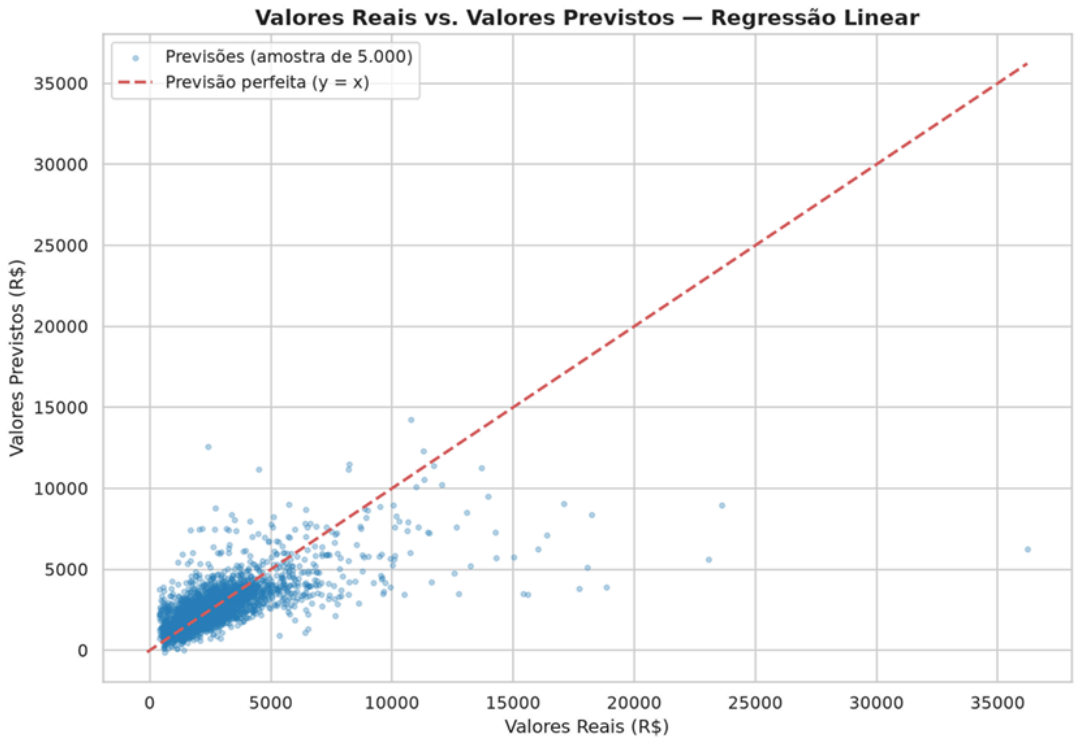
Faixa de remuneração real	Registros	MAE (R$)	Resíduo médio (R$)
Até R$ 1.500	4.933	482,36	−342,88
R$ 1.500 a R$ 2.500	6.761	445,55	−184,61
R$ 2.500 a R$ 5.000	4.647	662,53	195,18
Acima de R$ 5.000	810	2.967,36	2.644,40

Fonte: Elaborado pelos autores (2026), a partir do notebook TED03.ipynb.

28.3 Valores reais e previstos e resíduos

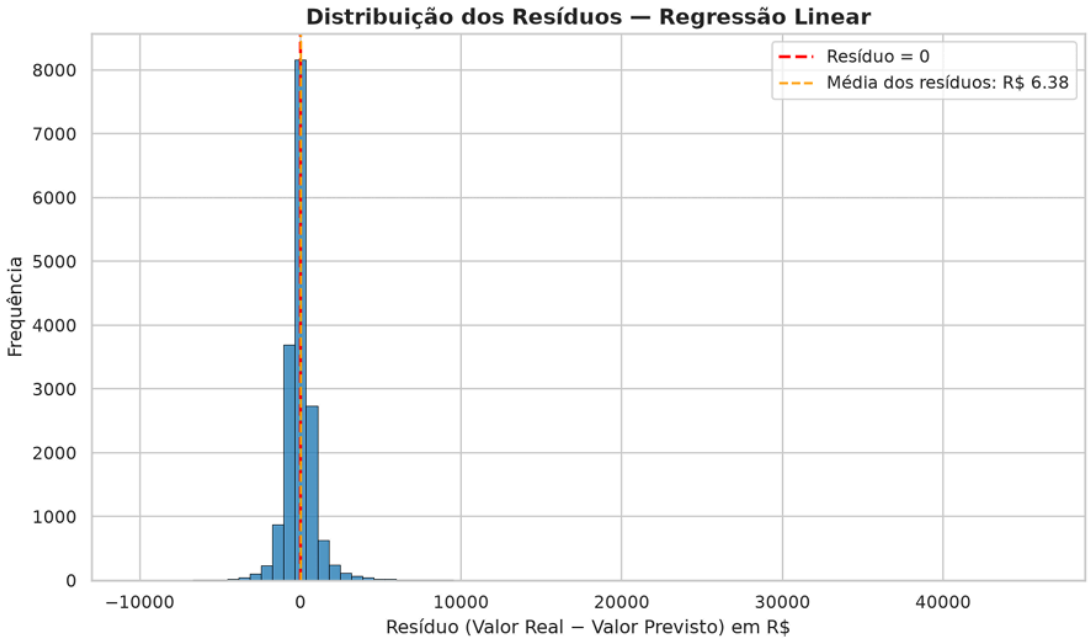
A Figura 2 confronta valores reais e previstos em uma amostra de 5.000 registros do conjunto de teste, e a Figura 3 mostra a distribuição dos resíduos (valor real menos valor previsto). Os resíduos têm média de R$ 6,38, mediana de R$ −44,11 e desvio-padrão de R$ 1.222,33.

Figura 2 – Valores reais e valores previstos pela regressão linear (amostra de 5.000 registros do teste)



Fonte: Elaborado pelos autores (2026), a partir do notebook TED03.ipynb.

Figura 3 – Distribuição dos resíduos da regressão linear no conjunto de teste



Fonte: Elaborado pelos autores (2026), a partir do notebook TED03.ipynb.

28.4 IMPORTÂNCIA DAS VARIÁVEIS

Os coeficientes das variáveis numéricas indicam associações positivas com a remuneração prevista dentro do modelo ajustado. Entretanto, devido à codificação das variáveis categóricas e à multicolinearidade resultante da representação utilizada, esses

valores devem ser interpretados com cautela, não representando necessariamente efeitos individuais isolados. A ocupação concentra os maiores coeficientes, mas as categorias com poucos registros apresentam estimativas instáveis.

29 INTERPRETAÇÃO DOS RESULTADOS

O modelo explica cerca de 47,5% da variação da remuneração, bem acima do baseline (R^2 igual a zero). Isso mostra que ocupação, setor, porte e perfil carregam informação real sobre o salário, coerente com os padrões da análise exploratória da TED 02. Os 52,5% restantes dependem de fatores ausentes da base, como a negociação individual, a experiência específica e o valor efetivamente praticado por obra.

O MAE de R$ 634,03 equivale a cerca de 27% da remuneração média (R$ 2.364,39) e a 32% da mediana (R$ 1.973,40). O erro típico é menor que o médio: metade das previsões erra menos de R$ 374. Para o usuário, isso significa uma referência aproximada por função e perfil, e não um valor exato.

O RMSE é quase o dobro do MAE, o que indica que poucos erros muito grandes elevam a métrica. A Tabela 4 confirma o diagnóstico: nos 810 registros acima de R$ 5.000 o erro médio chega a R$ 2.967,36, cerca de seis vezes o das faixas mais baixas. O erro também tem direção: o resíduo médio é de R$ 2.644,40 na faixa mais alta e de R$ −342,88 na mais baixa, isto é, o modelo subestima os salários altos e superestima os baixos, aproximando as previsões da média. Esses salários altos são raros e concentrados em cargos de direção e de nível superior, e a Figura 2 mostra os pontos se afastando da diagonal a partir de cerca de R$ 5.000.

A média dos resíduos próxima de zero indica que o modelo não erra sistematicamente para cima ou para baixo no conjunto, mas a mediana negativa e a cauda à direita da Figura 3 refletem os salários altos que ele não captura. A estabilidade entre treino, teste e validação cruzada (Tabela 2) indica boa capacidade de generalização dentro do recorte avaliado.

30 LIMITAÇÕES IDENTIFICADAS

a) Distância entre dado e problema: a RAIS registra a remuneração mensal média de vínculos formais do setor no Maranhão em 2023; não há obra, frequência, meia diária nem valor de diária, de modo que o modelo não prevê o custo de mão de obra da Conserpav;

b) Cauda de salários altos: a assimetria de 6,28 e os 810 registros acima de R$ 5.000, com erro médio de R$ 2.967,36, concentram o erro; o alvo não foi transformado (por exemplo, em logaritmo) e os valores extremos não foram tratados;

c) Ocupações raras: das 719 ocupações (CBO), 392 possuem menos de 10 registros, e a codificação gera 742 colunas de entrada, o que torna instáveis os coeficientes de categorias pequenas e favorece o sobreajuste nelas; ocupações ausentes do treino têm contribuição zerada pelo parâmetro handle_unknown='ignore';

d) Previsões fora da faixa válida: a regressão linear não restringe a saída, e oito previsões no teste ficaram negativas;

e) Capacidade do modelo: um R^2 de 0,475 indica que mais da metade da variação depende de fatores fora da base; relações não lineares e interações, como ocupação por porte do estabelecimento, não são capturadas por um modelo linear;

f) Avaliação: há uma divisão aleatória única, complementada pela validação cruzada; como a base cobre apenas o ano de 2023, não foi possível uma divisão temporal, e a generalização para outros anos ou estados não foi testada;

g) Representatividade e viés: 92,1% dos vínculos possuem sexo com código 1 (masculino), refletindo o desequilíbrio presente na base do setor. Como o sexo foi utilizado como variável preditora, o modelo pode reproduzir diferenças históricas de remuneração presentes nos dados. Em uma aplicação real, essa variável exigiria avaliação ética específica, sendo recomendável comparar o desempenho do modelo com e sem sua utilização, evitando que estimativas salariais reproduzam possíveis desigualdades.
h) Documentação: o critério de exclusão das colunas que não entraram no modelo não está registrado coluna a coluna.

31 RELAÇÃO COM O PROJETO E COM O MVP

O modelo contribui para resolver o problema definido?

Em parte. Ele não substitui a previsão do custo do próximo período prevista na TED 01, que depende do histórico de frequência e pagamentos da própria empresa, ainda inexistente. Contribui por validar a etapa de modelagem do fluxo (preparação, pipeline do scikit-learn e avaliação contra um baseline) com dados reais do setor.

Os resultados são adequados ao objetivo proposto?

Como referência de mercado, sim, com ressalvas. Um erro médio absoluto de R$ 634 (cerca de 27% da remuneração média) serve para orientar, mas não para definir valores definitivos. Os indicadores de validação da TED 01 (diferença entre previsto e real e percentual de erro) também foram aplicados ao conjunto de teste: o erro percentual absoluto mediano foi de 18,8%.

Quais variáveis parecem relevantes?

A ocupação é a mais relevante, seguida do setor e do porte do estabelecimento, o que é coerente com os resultados da TED 02. Idade, jornada e tempo de emprego apresentam menor influência no modelo. Os coeficientes associados a ocupações com poucos registros, porém, não devem ser interpretados individualmente.

Quais são as principais limitações?

As descritas na seção 10, especialmente a diferença entre os dados da RAIS e a realidade operacional da CONSERPAV, além do erro mais elevado nas estimativas de salários altos.

Em quais condições o modelo poderia ser utilizado?

Nas situações seguintes, sempre apresentado como estimativa, e não como valor definitivo, em linha com a TED 01:
a) como valor de referência por função e perfil ao cadastrar um funcionário ou elaborar o orçamento de uma obra nova, quando a empresa ainda não possui histórico próprio;

b) como alerta de conferência, sinalizando valores muito acima ou abaixo do esperado para determinada função.

Como os resultados contribuem para a evolução do MVP?

A estrutura do pipeline pode ser reaproveitada quando o sistema acumular dados próprios de frequência e pagamentos por período. Nesse cenário, o mesmo fluxo de preparação, treinamento e avaliação poderá ser aplicado à previsão dos custos reais das obras. Enquanto a empresa ainda não possuir histórico suficiente, o modelo baseado na RAIS poderá servir como referência inicial de mercado.

Assim, a modelagem demonstra a viabilidade técnica de incorporar mecanismos preditivos ao sistema CONSERPAV e estabelece um ponto de partida para o desenvolvimento de modelos mais aderentes à realidade operacional da empresa.

32 REGISTRO DE DECISÕES E PRÓXIMOS EXPERIMENTOS

O Quadro 4 registra as decisões tomadas nesta etapa. Duas decisões da TED 02 foram alteradas, conforme a seção 3.2. Os experimentos realizados foram os dois modelos descritos (baseline e regressão linear), a validação cruzada e a comparação entre cenários de tratamento.

Quadro 4 – Decisões tomadas na TED 03

Decisão	**Motivo**
Regressão em vez de classificação ou agrupamento	O alvo é um valor em reais
Alvo: valor_remuneracao_media	Única medida de pagamento disponível na RAIS
Excluir remuneração igual a zero	Não representa o salário real e distorce o ajuste
Remover duplicidades antes da divisão	Evitar linhas idênticas em treino e teste; efeito medido em 3.2
Baseline DummyRegressor	Dar referência para julgar o ganho do modelo
Pipeline e ColumnTransformer	Evitar vazamento de informação do teste
Regressão linear	Simples, rápida e interpretável
Divisão 80/20 e validação cruzada, semente 42	Reprodutibilidade e verificação de generalização

Fonte: Elaborado pelos autores (2026).

Os próximos experimentos, ainda não realizados, são:

a) aplicar logaritmo ao alvo, para reduzir a assimetria e o peso dos salários altos;

b) agrupar ocupações raras (por exemplo, pelos primeiros dígitos do código CBO) ou usar regularização (Ridge e Lasso);
c) comparar com modelos não lineares, como Random Forest e Gradient Boosting;
d) limitar as previsões ao intervalo válido (maior ou igual a zero);
e) repetir o pipeline com os dados reais de frequência e pagamentos da Conserpav, quando existirem.

33 CONCLUSÃO DA TED 03

A TED 03 desenvolveu e avaliou um modelo de regressão linear para estimar a remuneração média mensal de vínculos da construção civil no Maranhão, a partir da base preparada na TED 02. O modelo reduziu o erro absoluto médio de R$ 995,09 (baseline) para R$ 634,03 e explicou cerca de 47,5% da variação da remuneração, resultado estável na validação cruzada (R^2 médio de 0,482).

Os resultados mostram que ocupação e setor, variáveis destacadas na análise exploratória, de fato explicam parte relevante da remuneração, mas que o modelo erra de forma sistemática nos salários mais altos e que uma parcela grande da variação depende de fatores ausentes da base. O modelo é adequado como referência salarial do setor, não como previsão do custo da Conserpav, que dependerá do histórico operacional gerado pelo próprio sistema. O fluxo desenvolvido nesta etapa poderá ser reaproveitado quando esse histórico existir.

REFERÊNCIAS

BASE DOS DADOS. Relação Anual de Informações Sociais (RAIS). Disponível em: https://basedosdados.org/dataset/3e7c4d58-96ba-448e-b053-d385a829ef00?table=86b69f96-0bfe-45da-833b-6edc9a0af213. Acesso em: 26 set. 2026.

BRASIL. Ministério do Trabalho e Emprego. Microdados RAIS e CAGED. Brasília, DF: Ministério do Trabalho e Emprego. Disponível em: https://www.gov.br/trabalho-e-emprego/pt-br/assuntos/estatisticas-trabalho/microdados-rais-e-caged. Acesso em: 26 set. 2026.

CONSERPAV BIG DATA. CONSERPAV-BIG-DATA. GitHub, 2026. Disponível em: https://github.com/CarlosOliveira7/CONSERPAV-BIG-DATA. Acesso em: 3 nov. 2026.

MCKINNEY, W. Data structures for statistical computing in Python. In: PYTHON IN SCIENCE CONFERENCE, 9., 2010, Austin. Proceedings [...]. Austin: SciPy, 2010. p. 56-61.

PEDREGOSA, F. et al. Scikit-learn: machine learning in Python. Journal of Machine Learning Research, v. 12, p. 2825-2830, 2011.