UNIBALSAS Centro Universitário

ANÁLISE E DESENVOLVIMENTO DE SISTEMAS

ANDREI PEREIRA LIMA
CARLOS OLIVEIRA LOPES
KAIO MOREIRA MORAIS
PRISCILA FERREIRA DIAS SANTOS
YWD RHAVELL FERREIRA CARVALHO

TED 01 – DEFINIÇÃO DO PROBLEMA DE DADOS E SELEÇÃO DO CONJUNTO DE DADOS

BALSAS - MA
2026

1. PROBLEMA DO PROJETO

O projeto tem como cliente a Conserpav uma empresa voltada para o setor de obras e pavimentação que precisava de uma solução tecnológica para resolver um gargalo antigo: o controle de presença e o fechamento de pagamento dos trabalhadores.Hoje, boa parte dessa rotina ainda é tocada de forma bem manual, usando cadernos, anotações soltas e planilhas. No canteiro de obras, o responsável anota a frequência no dia a dia, confere quem trabalhou o período completo, meio período ou faltou, e depois cruza tudo isso para calcular quanto cada um deve receber. Esse modelo tradicional acaba gerando uma série de dores de cabeça. É comum acontecerem erros de soma, perda de informações, retrabalho na hora de fechar a folha e muita dificuldade para resgatar dados de períodos anteriores. Para piorar, como os ciclos de pagamento variam entre semanais e quinzenais, o acompanhamento histórico dos custos com mão de obra vira um quebra-cabeça.O grande objetivo da nossa solução é justamente eliminar essa bagunça. Criamos uma ferramenta centralizada que não só simplifica o registro de frequência e o cálculo dos pagamentos, mas também aproveita o histórico gerado na obra para dar mais previsibilidade financeira aos gestores nos próximos períodos.

2. DESCRIÇÃO DA SOLUÇÃO E MVP

A proposta consiste no desenvolvimento de um sistema web inteligente voltado para a gestão de frequência, cálculo de pagamentos e projeção de custos com mão de obra. A plataforma viabiliza o registro diário da presença dos trabalhadores, realiza a apuração automática dos valores devidos e consolida o histórico financeiro dos canteiros de obras.

Como principal diferencial, a ferramenta emprega recursos de Inteligência Artificial para analisar a base de dados histórica e estimar os custos de pessoal para o próximo ciclo de fechamento. Essa projeção subsidia o planejamento financeiro ao ponderar variáveis como:

- Quantidade de trabalhadores alocados;
- Valores estipulados para as diárias;
- Média de dias efetivamente trabalhados;
- Ocorrência de jornadas parciais (meias diárias);
- Despesas consolidadas em períodos anteriores;
- Comportamento macro dos gastos na obra.

Cumpre destacar que a previsão possui caráter estritamente estimativo, servindo como suporte analítico à tomada de decisão e preservando a autonomia do gestor responsável pela obra.

2.1 FUNCIONALIDADES DO MVP

O Produto Mínimo Viável (MVP) contempla os seguintes módulos e funcionalidades:

- **Cadastro de obras:** Permite o registro dos empreendimentos e a configuração do ciclo de fechamento aplicável (semanal ou quinzenal).
- **Cadastro de funcionários:** Gerencia o registro individual contendo nome, função, valor da diária, obra vinculada e chave Pix.
- **Registro de frequência:** Possibilita o apontamento diário da situação de cada trabalhador, distinguindo entre diária completa, meia diária e ausência.
- **Cálculo automático de pagamentos:** Efetua o cômputo dos valores devidos com base direta nos apontamentos de frequência.
- **Histórico:** Disponibiliza consultas consolidadas aos registros de presença e pagamentos de ciclos anteriores.
- **Relatório de pagamento:** Emite demonstrativos contendo o nome do funcionário, a somatória de dias completos, meios dias, faltas, o montante total a pagar e a respectiva chave Pix.
- **Previsão de custos com IA:** Centraliza o recurso preditivo voltado à estimativa de gastos para o período subsequente. A interface exibe parâmetros como:
    - Custo estimado para a próxima quinzena (ex: R$ 18.450,00);
    - Custo incorrido no período anterior;
    - Média histórica dos ciclos passados;
    - Projeção vigente e variação percentual estimada.

3. NECESSIDADES DE DADOS DA SOLUÇÃO

Com base no problema identificado e nas funcionalidades do MVP, as principais necessidades de dados são apresentadas a seguir.

Necessidade de dados	Utilização no projeto
Identificação da obra	Associar os registros ao projeto correspondente
Identificação do trabalhador	Associar frequência e pagamentos ao funcionário
Função do trabalhador	Permitir análise da composição da mão de obra
Valor da diária / remuneração	Calcular o pagamento
Data do registro / admissão / desligamento	Organizar a frequência e o vínculo ao longo do tempo
Situação da frequência	Identificar diária completa, meia diária ou ausência
Quantidade de trabalhadores	Avaliar a demanda de mão de obra

Necessidade de dados	Utilização no projeto
Duração da obra / do vínculo	Relacionar duração e necessidade de recursos
Custo da obra / folha de pagamento	Analisar o comportamento dos custos
Histórico de custos	Apoiar a previsão de custos futuros

4. PESQUISA E COMPARAÇÃO DE CONJUNTOS DE DADOS

Após pesquisas em repositórios públicos de dados, como o Kaggle, as alternativas encontradas apresentaram baixa aderência ao problema: algumas eram voltadas a outros aspectos da obra, como qualidade e segurança, outras continham dados simulados, e outras tratavam de setores e contextos geográficos sem relação com o projeto, nenhuma trazendo variáveis reais de frequência, remuneração ou custo de mão de obra da construção civil.

Diante disso, a equipe optou por uma base governamental oficial: os microdados de vínculos da RAIS (Relação Anual de Informações Sociais), disponibilizados pelo Ministério do Trabalho e Emprego, que foi a que apresentou maior correspondência com as necessidades de dados do projeto e permite um recorte real e verificável para o setor de construção civil. O CAGED, também mantido pelo MTE, foi considerado, mas não é utilizado nesta etapa.

5. CONJUNTO DE DADOS SELECIONADO

A base escolhida são os microdados de vínculos da RAIS (Relação Anual de Informações Sociais), ano-base 2023, registro administrativo do mercado de trabalho formal brasileiro mantido pelo Ministério do Trabalho e Emprego (MTE) por meio do PDET. Trata-se de dado público governamental, de acesso livre para fins estatísticos e de pesquisa, com registros não identificados.

Originalmente, o MTE disponibiliza os arquivos em formato texto (.txt), delimitados por ponto e vírgula, via FTP. Para evitar o processamento dos arquivos nacionais, a equipe utilizou a plataforma Base dos Dados, que oferece a série da RAIS estruturada em tabelas no BigQuery. A consulta filtrou o estado do Maranhão, as divisões 41, 42 e 43 da CNAE 2.0 (construção) e o ano de 2023, e o resultado foi exportado em CSV.

Fonte oficial (MTE):
https://www.gov.br/trabalho-e-emprego/pt-br/assuntos/estatisticas-trabalho/microdados-rais-e-caged

- Acesso estruturado (Base dos Dados): https://basedosdados.org/dataset/3e7c4d58-96ba-448e-b053-d385a829ef00?table=86b69f96-0bfe-45da-833b-6edc9a0af213
- Tabela consultada: basedosdados.br_me_rais.microdados_vinculos
- Link Repositorio: https://github.com/CarlosOliveira7/CONSERPAV-BIG-DATA
- Recorte utilizado (Drive): https://drive.google.com/file/d/1mK4umhCU6nULcQEdCCYs7DxAyQH38HB2/view
- Consulta utilizada:

```sql
SELECT *
FROM `basedosdados.br_me_rais.microdados_vinculos`
WHERE ano = 2023
  AND sigla_uf = 'MA'
  AND SUBSTR(cnae_2, 1, 2) IN ('41', '42', '43')
```

Os microdados da RAIS são dados públicos governamentais, não identificados, de livre acesso para fins estatísticos e de pesquisa. O tratamento e a disponibilização em tabelas foram feitos pela Base dos Dados, cujas condições de uso constam na página do conjunto (link acima). Por se tratar de dados públicos e sem identificação de pessoas, o recorte utilizado foi disponibilizado no repositório do projeto.

6. PRINCIPAIS ATRIBUTOS/VARIÁVEIS

A base possui 67 atributos. Os mais relevantes para o projeto são:

1. **Setor e função: cnae_2** identifica o setor do estabelecimento e permite isolar a construção civil. **cbo_2002** (Classificação Brasileira de Ocupações) aproxima a "função" prevista no MVP, com códigos para pedreiro, servente, carpinteiro e outras ocupações.
2. **Remuneração: valor_remuneracao_media** (média mensal em R$) e **valor_remuneracao_media_sm** (em salários mínimos) funcionam como proxy do valor de mão de obra. A base traz ainda a remuneração de cada mês (**valor_remuneracao_janeiro** a **valor_remuneracao_dezembro**), que permite observar a evolução dos custos ao longo do ano.
3. **Vínculo e tempo: mes_admissao**, **mes_desligamento**, **tempo_emprego**, **vinculo_ativo_3112** (ativo em 31/12) e **tipo_vinculo**.
4. **Jornada: quantidade_horas_contratadas** e **indicador_trabalho_parcial** fornecem, de forma limitada, uma aproximação da jornada reduzida (meia diária), já que apenas 0,40% dos vínculos são marcados como trabalho parcial.
5. **Localização e porte: id_municipio**, **sigla_uf** e **tamanho_estabelecimento**.
6. **Perfil do trabalhador: sexo**, **idade**, **grau_instrucao_apos_2005** e **raca_cor**.
7. **Referência temporal: ano**, com a possibilidade de incluir outros anos-base para formar série multianual.

7. QUANTIDADE DE REGISTROS

A tabela de microdados de vínculos da RAIS de 2023 possui **82.966.522** registros. Ao filtrar o estado do Maranhão (`sigla_uf = 'MA'`), obtiveram-se **1.265.961** registros (1,53% do total nacional). Aplicando o recorte das divisões 41, 42 e 43 da CNAE 2.0, correspondentes às atividades de construção, chegou-se a **97.971 registros e 67 atributos** (7,74% dos vínculos do Maranhão), que constituem a base utilizada nas etapas seguintes.

A distribuição por divisão é: 50.096 vínculos na divisão 41, construção de edifícios (51,13%); 34.148 na divisão 42, obras de infraestrutura (34,86%); e 13.727 na divisão 43, serviços especializados para construção (14,01%). O volume é suficiente para as análises propostas, mantendo o alinhamento com o contexto geográfico e setorial do projeto.

8. FORMATO DOS DADOS

Os dados são disponibilizados originalmente pelo MTE em arquivos de texto delimitados por ponto e vírgula, acessíveis via protocolo FTP, o que dificulta o uso direto em navegadores modernos. Como alternativa mais prática, a equipe consultou apenas o recorte necessário via SQL na Base dos Dados (BigQuery) e o exportou em **CSV**, formato que facilita a leitura em Python e Pandas e a conversão posterior para outros formatos, como Parquet.

9. AVALIAÇÃO PRELIMINAR DA QUALIDADE DOS DADOS

A avaliação foi feita sobre o recorte da RAIS 2023 para o Maranhão e as divisões 41 a 43 da CNAE 2.0, com 97.971 registros e 67 atributos, obtido via Base dos Dados.

Completude. 58 das 67 colunas não apresentam valores ausentes, incluindo as variáveis centrais ao projeto: **valor_remuneracao_media**, **cbo_2002**, **cnae_2**, **tempo_emprego**, **mes_admissao** e a remuneração de janeiro a novembro. Nove colunas têm nulos:

- **Cinco estão 100% vazias** (`tipo_salario`, `valor_salario_contratual`, `subatividade_ibge`, `cbo_1994` e `grau_instrucao_1985_2005`) e serão descartadas. `cbo_1994` e `grau_instrucao_1985_2005` são atributos de classificações antigas, e `subatividade_ibge` não é preenchida neste recorte.
- **id_municipio_trabalho** tem 99,97% de nulos.
- **motivo_desligamento** tem 51,33% de nulos, provavelmente associados a vínculos sem desligamento no ano.
- **valor_remuneracao_dezembro** tem 53,73% de nulos, o que difere dos demais meses e deve ser investigado.
- **natureza_juridica** tem 29,78% de nulos.

Colunas específicas de outras localidades (**bairros_sp**, **distritos_sp**, **bairros_fortaleza**, **bairros_rj** e **regioes_administrativas_df**) não têm nulos, mas estão preenchidas com códigos de "não se aplica" (por exemplo, 999997 em **bairros_sp** para todos os registros), e serão descartadas.

Duplicidades. Foram encontrados 542 registros duplicados (0,55%). Como a base é anonimizada e não possui identificador de vínculo ou de trabalhador, linhas idênticas podem ser vínculos distintos com as mesmas características, e não necessariamente erros. Esse ponto será analisado antes de qualquer remoção.

Valores suspeitos. A remuneração média mensal tem média de R$ 2.074,61, mediana de R$ 1.833,48 e máximo de R$ 72.837,96, indicando forte assimetria à direita. 11.840 vínculos (12,09%) têm remuneração média igual a zero: 6.827 deles estão inativos em 31/12 e 5.013 ativos. Isso pode indicar vínculos sem pagamento no ano, afastamentos ou registros com informação incompleta, e exigirá análise específica. Apenas 34 vínculos (0,03%) têm remuneração acima de 20 salários mínimos e serão tratados como possíveis outliers. A idade varia de 15 a 85 anos (média de 37,7 e mediana de 37), sem incoerências evidentes, embora as idades extremas devam ser verificadas.

Estrutura e formato. Diversos atributos são códigos numéricos que dependem de tabelas de domínio externas (CNAE, CBO, município, tipo de vínculo, grau de instrução). Há também atributos irrelevantes ao problema, como os de deficiência (98,87% dos registros sem deficiência), nacionalidade e ano de chegada ao Brasil, que poderão ser descartados.

Granularidade e natureza dos dados. A remuneração é uma média mensal declarada pelo empregador uma vez ao ano, e não o valor de uma diária. A base cobre apenas vínculos formais e não registra frequência diária. As informações temporais se limitam a mês de admissão, mês de desligamento, tempo de emprego e remuneração mensal. Como **tipo_salario** e **valor_salario_contratual** estão vazios, não é possível identificar contratos remunerados por hora ou por dia. Apenas 393 vínculos (0,40%) são marcados como trabalho parcial, o que limita a analogia com a meia diária. Por serem dados anonimizados, não é possível identificar obras ou trabalhadores individualmente.

Implicações para as próximas etapas. Será necessário: descartar as colunas vazias, de outras localidades e irrelevantes; decidir o tratamento das remunerações zeradas (12,09%) e dos outliers; avaliar as duplicidades; decodificar CNAE e CBO; e, caso outros anos sejam incluídos, corrigir os valores pela inflação ou pelo salário mínimo. Os resultados devem ser interpretados como referência do setor no Maranhão, e não como retrato das obras da Conserpav.

10. JUSTIFICATIVA DA ESCOLHA DA BASE DE DADOS

A escolha da RAIS partiu da baixa aderência das alternativas pesquisadas, que eram simuladas, pertenciam a outro setor ou tratavam de aspectos da obra distintos de frequência e custo de mão de obra. Em contrapartida, a RAIS é uma base real, oficial e verificável, produzida pelo MTE, com remuneração efetivamente declarada e filtrável para o setor de construção e para o Maranhão. Após o recorte, restaram 97.971 vínculos, volume suficiente para análises estatísticas e experimentos de modelagem.Outro fator relevante é a remuneração mensal detalhada de cada vínculo (janeiro a dezembro), que permite observar a evolução dos custos de mão de obra ao longo do ano, algo diretamente relacionado à previsão de custos do MVP. A fonte também disponibiliza outros anos-base, o que poderá ampliar o recorte para uma série multianual nas próximas etapas.Por ser um registro administrativo de vínculos formais com periodicidade anual, a base não reproduz o registro diário de frequência do sistema da Conserpav. Isso é compatível com o caráter preliminar e exploratório desta etapa, que prevê justamente a identificação dessas limitações.

11. RELAÇÃO ENTRE OS DADOS, O PROBLEMA E AS LIMITAÇÕES

O controle manual da frequência e a dificuldade de prever custos de mão de obra geram a necessidade de dados de remuneração, vínculo, ocupação, setor e histórico temporal. Essas necessidades são parcialmente atendidas pela RAIS filtrada para construção civil no Maranhão. A função do trabalhador é representada pelo **`cbo_2002`**; a quantidade de mão de obra pode ser obtida pela contagem de vínculos por CNAE, município e período; o valor pago é aproximado pela remuneração média mensal; a duração do vínculo é aproximada por **`tempo_emprego`** e pelos meses de admissão e desligamento; e o comportamento dos custos ao longo do tempo pode ser observado pela remuneração de cada mês.A relação não é completa. A base trabalha com o estabelecimento empregador, e não com a "obra"; não permite identificar nominalmente um funcionário; e não contém registros diários de frequência (diária completa, meia diária, ausência) nem histórico de pagamentos individuais. Cobre apenas vínculos formais (CLT), deixando de fora a mão de obra informal ou por diária avulsa, comum em obras. Existe ainda a diferença conceitual entre a remuneração mensal declarada e o valor de uma diária específica, agravada pelo fato de os campos de tipo de salário e salário contratual estarem vazios e de apenas 0,40% dos vínculos serem de trabalho parcial. Na prática, a leitura de CNAE e CBO depende de tabelas de domínio externas, e por ser fonte secundária, seus padrões devem ser lidos como referência do setor, e não como retrato das obras da Conserpav.

Essa aderência parcial é esperada nesta etapa e não impede o uso da base como referência. Nas etapas seguintes, ela poderá apoiar uma análise exploratória da remuneração por ocupação, município e mês, a observação da evolução mensal dos custos como referência de tendência e a experimentação de modelos de regressão com Scikit-learn para estimar custos do setor. Em paralelo, a análise ajuda a equipe a definir o que o sistema da Conserpav deverá armazenar para, no futuro, treinar um modelo com granularidade diária. Uma estrutura histórica compatível com o MVP é ilustrada a seguir:

Data	Obra	Funcionário	Função	Diária	Frequência	Valor pago
01/09/2026	Obra A	Funcionário 1	Pedreiro	150	Completa	150
01/09/2026	Obra A	Funcionário 2	Servente	100	Meia	50

02/09/2026	Obra A	Funcionário 1	Pedreiro	150	Completa	150

Com o acúmulo desses registros ao longo do uso do sistema, a equipe poderá construir uma base própria e diretamente relacionada ao objetivo do projeto, futuramente comparável aos padrões observados na RAIS para o setor de construção civil.

REFERÊNCIAS BIBLIOGRÁFICAS

BRASIL. Ministério do Trabalho e Emprego. Microdados RAIS e CAGED. Disponível em: https://www.gov.br/trabalho-e-emprego/pt-br/assuntos/estatisticas-trabalho/microdados-rais-e-caged. Acesso em: 14 set. 2026.

BASE DOS DADOS. *RAIS – Microdados de vínculos*. Disponível em: https://basedosdados.org/dataset/3e7c4d58-96ba-448e-b053-d385a829ef00?table=86b69f96-0bfe-45da-833b-6edc9a0af213.